

Métodos de avaliação de frases em português e resultados em pipeline

Matheus Sales*

Resumo

Dada uma frase isolada, sem gabarito e sem referência, coloca-se a questão de quanto se pode afirmar automaticamente a respeito de sua boa formação. Este trabalho levanta onze métodos de avaliação aplicáveis ao português brasileiro — léxicos, gramáticas de padrões, analisadores sintáticos, modelos de n -grama, modelos mascarados e vetores distribucionais —, descreve cada um sob um formalismo único e submete todos a um mesmo conjunto controlado de pares mínimos. A caracterização mostra que os métodos não são intercambiáveis nem ordenáveis por qualidade: suas coberturas são complementares, e nem toda medida bem definida constitui um detector de desvio. Quatro das medidas examinadas degeneram — uma reduz-se a função exclusiva do comprimento da frase, uma converge para uma constante determinada por um hiperparâmetro de suavização, uma reduz-se à frequência isolada da palavra e uma é invariante a toda permutação —, e as quatro degenerações são estabelecidas por demonstração, e não por medição. Dos métodos que sobrevivem à caracterização compõe-se uma *pipeline* de quatro etapas, cuja ordem decorre das propriedades medidas e cujo veredito resulta da vacuidade de um conjunto de achados localizados, com um único parâmetro calibrável em toda a cadeia. Reportam-se os resultados da pipeline sobre o mesmo corpus, incluindo a propagação de erro entre etapas e os tipos de desvio que ela não alcança.

Palavras-chave: avaliação automática de frases; pares mínimos; aceitabilidade linguística; análise de dependências; língua portuguesa.

1 Introdução

A avaliação automática de uma frase isolada, sem gabarito e sem referência, constitui problema de ordem prática antes de teórica. Um sistema que redige *Há três dias o incêndio atingiu uma área de mata nativa* a partir dos campos de um registro de eventos de fogo precisa verificar o que produziu, e não dispõe de termo de comparação: não há tradução de origem nem resumo humano. Métricas que pressupõem um texto de referência, como BLEU e ROUGE, não se aplicam, e a verificação recai sobre a frase em si.

Os métodos disponíveis para essa tarefa são numerosos e heterogêneos: léxicos associados a distância de edição (Damerau, 1964; Levenshtein, 1966; Kukich, 1992), gramáticas de padrões escritos manualmente (Naber, 2003; Miłkowski, 2010), analisadores sintáticos (Nivre *et al.*, 2016; Rademaker *et al.*, 2017), modelos de linguagem dos quais derivam medidas de aceitabilidade como o SLOR (Pauls; Klein, 2012; Lau; Clark; Lappin, 2017) e a pseudo-log-verossimilhança (Wang; Cho, 2019; Salazar *et al.*, 2020), e vetores distribucionais (Mikolov *et al.*, 2013). Não respondem, contudo, à mesma pergunta: alguns produzem veredito exato, outros veredito estimado, e outros apenas um valor numérico.

*Contato: matheusvmsales1@gmail.com

2 Metodologia

O procedimento adotado parte de uma frase correta, modificada de forma controlada. Cada variante introduz um único desvio, de tipo conhecido. Todos os métodos são aplicados às mesmas frases, e observa-se o que cada um detecta, o que deixa passar e por qual mecanismo.

A frase de referência é *Há três dias o incêndio atingiu uma área de mata nativa*, redigida a partir dos campos de um registro de eventos de fogo. Dela derivam as doze variantes apresentadas na Tabela 1.

Variante	Nível afetado	Alteração introduzida
natvia	ortografia	forma inexistente no léxico
A três dias	escolha lexical	forma existente, mas inadequada
uma áreas	concordância nominal	determinante × núcleo
a área inteiro	concordância nominal	adjetivo posposto
os incêndios atingiu	concordância verbal	sujeito nominal × verbo
cantou	semântica	restrição de seleção violada
que atingiu	estrutura	relativa sem oração principal
Atingir...	estrutura	infinitivo isolado
ordem embaralhada	ordem	as onze palavras permutadas
tres + áreas + natvia	múltiplo	três desvios simultâneos
destruiu	—	paráfrase plausível (controle)
O incêndio é intenso	—	predicação nominal (controle)

Tabela 1: As doze variantes da frase de referência.

As duas últimas linhas não contêm desvio e destinam-se a verificar o inverso: um método que as acusa produz falso positivo. A forma **destruiu** constitui paráfrase igualmente correta, e *O incêndio é intenso* é predicação nominal legítima, em que o verbo não ocupa a raiz da árvore.

Seis frases auxiliares completam o corpus. Duas comparam complexidade sintática sob o mesmo número de palavras, duas comparam comprimento de dependência com as mesmas palavras em ordens distintas, e duas formam um par de permutação. São necessárias porque os descritores só se distinguem quando o comprimento é mantido fixo.

Os onze métodos distribuem-se por quatro dimensões, cada uma associada a uma verificação distinta. A ortografia verifica se as palavras existem; a gramática, se elas concordam entre si; a estrutura, se a frase dispõe de predicado e como suas partes se articulam; e a semântica, se o enunciado é plausível. A divisão não é apenas organizativa, uma vez que cada dimensão pressupõe a anterior: não se avalia concordância sobre uma palavra que não existe, nem plausibilidade sobre uma frase desprovida de predicado. É essa dependência que determina a ordem das etapas da *pipeline*.

Nenhum modelo foi treinado ou ajustado. Todos os recursos são de prateleira, e os limites observados adiante pertencem a eles, e não ao método: a substituição do analisador sintático altera o resultado sem alterar uma linha da regra. O analisador declara acerto de 95,6% nos traços morfológicos e de 86,0% nos arcos de dependência, valores que a Seção 4 retoma ao discutir os falsos negativos.

3 Os métodos

Cada subseção apresenta um método: o que ele mede, como é definido, o que detectou no corpus e o que deixou passar.

3.1 Léxico com distância de edição

O método não emprega modelo nem generalização. Opera sobre um conjunto finito de formas atestadas, cada uma associada à sua frequência, e decompõe-se em dois passos encadeados.

O primeiro é a detecção. Dado o léxico D ,

$$\text{erro}(w) = \begin{cases} 0, & w \in D \\ 1, & w \notin D \end{cases} \quad (1)$$

O predicado é exato: a palavra consta ou não consta do conjunto. Constitui o único veredito sem gradação nem limiar entre os onze métodos examinados.

O segundo é a correção. Seja $C_k(w)$ o conjunto das formas do léxico situadas a exatamente k edições de w . A busca é escalonada — a distância 2 só é consultada quando a distância 1 não devolve candidato algum — e, entre os candidatos admitidos, a frequência determina a escolha:

$$\hat{w} = \arg \max_{c \in C(w)} f(c) \quad (2)$$

A distância empregada é a de Damerau-Levenshtein, que computa a transposição de dois caracteres adjacentes como uma única edição. A escolha não é detalhe de implementação: é ela que situa **nativa** a uma edição de **natvia**. Sob métrica que não contemple a transposição, a permuta custaria 2, **nativa** ficaria fora do conjunto de candidatos e a correção emitida seria **naevia**.

O algoritmo não busca formas semelhantes. Ele enumera as 949 sequências situadas a uma edição de **natvia** e submete cada uma ao teste de pertinência a D ; quatro sobrevivem, conforme a Tabela 2.

c	Operação sobre natvia	$f(c)$
nativa	transposição de v e i	912
naevia	substituição de t por e	103
natia	remoção do v	77
latvia	substituição de n por l	23

Tabela 2: Candidatos a uma edição de **natvia**, com sua frequência no léxico.

Os quatro candidatos equidistam da forma detectada, de modo que a decisão recai integralmente sobre f . A frequência não opera como critério auxiliar de desempate, mas como único critério.

3.2 Traços morfossintáticos sobre a árvore de dependências

A concordância não constitui heurística passível de aproximação: define-se como igualdade de traços entre dois nós ligados na árvore sintática. O método transcreve literalmente essa definição.

O analisador associa a cada palavra t três informações: a classe gramatical, o núcleo $h(t)$ do qual ela depende e um mapa de traços

$$\mu_\tau(t) \in \{\text{valor}, \perp\} \quad (3)$$

em que τ designa o traço — **Number**, **Gender** ou **Person** — e $\perp$ indica ausência, uma vez que preposições e advérbios, entre outras classes, não portam número nem gênero. A árvore é o conjunto de arcos $A = \{(t, r, h(t))\}$, sendo r a função sintática.

Nem todo arco impõe concordância, e cada tipo impõe traços distintos. Seja $T(r)$ o conjunto de traços cuja coincidência o arco r exige:

$$T(r) = \begin{cases} \{\text{Number}, \text{Gender}\}, & r \in \{\text{det}, \text{amod}, \text{acl}\}, h(t) \text{ é NOUN/PROPN} \\ \{\text{Number}, \text{Person}\}, & r \in \{\text{nsubj}, \text{nsubj:pass}\}, h(t) \text{ é VERB/AUX} \\ \emptyset, & \text{caso contrário} \end{cases} \quad (4)$$

O conjunto de erros da frase é

$$E(s) = \{ (t, h, \tau) : (t, r, h) \in A, \tau \in T(r), \mu_\tau(t) \neq \perp, \mu_\tau(h) \neq \perp, \mu_\tau(t) \neq \mu_\tau(h) \} \quad (5)$$

e a frase é aceita quando $E(s) = \emptyset$.

Três decisões encontram-se inscritas na formulação. A guarda $\mu_\tau(\cdot) \neq \perp$ é obrigatória, pois na sua ausência toda palavra desprovida de número seria computada como discordante de seu núcleo e o método acusaria a frase integralmente. O terceiro caso, $T(r) = \emptyset$, previne o falso positivo mais frequente: em *as flores do jardim*, **jardim** liga-se a **flores** por **nmod**, e substantivos ligados por essa relação não estabelecem concordância entre si. A inclusão de **acl**, por fim, não é acessória: em *os dados coletados* o particípio recebe a função **acl** e a classe VERB, e não **amod**, de modo que sua omissão suprimiria integralmente a verificação de concordância de particípio.

A saída não é um escore. Sobre *Há três dias o incêndio atingiu uma áreas de mata nativa*, dos dez arcos apenas quatro são examinados, e o resultado é

$$E(s) = \{ (\text{uma}, \text{áreas}, \text{Number}) \} \quad (6)$$

isto é, a palavra responsável, o termo com o qual ela diverge e o traço violado, aos quais se soma o arco **det** que os liga. São quatro informações acionáveis, e nenhum outro método examinado localiza o desvio com essa precisão.

Cabe registrar um aspecto que a Seção 4 retoma: os traços não são lidos da palavra escrita, mas preditos do contexto pelo analisador. O que a fórmula recebe não é μ , e sim uma estimativa $\hat{\mu}$.

3.3 Regras escritas à mão

A gramática normativa encontra-se codificada em compêndios e gramáticas de referência. Este método não realiza inferência: cada regra é transcrita manualmente como um padrão sobre a sequência anotada, e o verificador busca casamentos.

A frase é tokenizada e anotada, constituindo uma sequência de triplas

$$s = \langle (w_1, \ell_1, p_1), (w_2, \ell_2, p_2), \dots, (w_n, \ell_n, p_n) \rangle \quad (7)$$

em que w_i designa a forma escrita, ℓ_i o lema e p_i a etiqueta morfológica.

Cada regra r consiste em um padrão π_r : expressão sobre essas triplas, análoga a uma expressão regular, porém operando sobre atributos linguísticos em lugar de caracteres. A regra dispara nas posições em que o padrão casa,

$$D_r(s) = \{ i : \pi_r \text{ casa em } s \text{ a partir da posição } i \} \quad (8)$$

e a saída do método é a união sobre a gramática R , o conjunto finito de regras elaboradas para o idioma:

$$D(s) = \bigcup_{r \in R} \{ (i, r) : i \in D_r(s) \} \quad (9)$$

A propriedade determinante do método é que R é finito e de elaboração manual. Daí decorre, sem gradação intermediária,

$$\text{erro} \notin \bigcup_{r \in R} \mathcal{L}(\pi_r) \implies \text{invisível} \quad (10)$$

em que $\mathcal{L}(\pi_r)$ designa o conjunto de construções que o padrão reconhece. Não há generalização nem grau de confiança: na ausência de regra correspondente, o desvio não é detectado. A cobertura do método equivale, portanto, ao trabalho humano investido no idioma — trabalho de natureza voluntária e distribuído de forma desigual entre as línguas. Para o português contabilizam-se 2.270 regras, reunidas em 249 grupos.

Sobre *A três dias o incêndio atingiu uma área de mata nativa*, uma única regra casa, na posição inicial:

$$D(s) = \{ (0, \text{CONFUSÃO_À_HÁ}) \} \quad (11)$$

A Tabela 3 apresenta os campos que acompanham o disparo.

Campo	Valor	Conteúdo
ruleId	CONFUSÃO_À_HÁ	a regra que casou — o r da fórmula
offset	0	a posição do casamento — o i da fórmula
errorLength	1	a extensão do casamento
trecho	'A'	o segmento coberto por π_r
replacements	['Há']	a correção que a regra carrega
message	"... substitua por há."	a norma, redigida em português

Tabela 3: Campos de um disparo do LanguageTool.

O par (i, r) constitui a localização. A última linha corresponde ao que nenhum outro método fornece: um enunciado em português que explicita a norma, redigido conjuntamente com o padrão. Trata-se, ademais, precisamente do caso que o léxico não alcança, uma vez que a pertence ao léxico e apenas uma regra de elaboração manual detecta a troca.

3.4 SLOR

Uma frase malformada é improvável sob um modelo de linguagem, o que sugeriria a leitura direta de $\ln P(s)$. A probabilidade bruta, entretanto, não distingue *raro* de *incorreto*: uma frase correta de vocabulário técnico é improvável por conter palavras improváveis, e não por má construção. O SLOR corrige essa indistinção descontando a contribuição atribuível à frequência isolada das palavras e normalizando pelo comprimento:

$$\text{SLOR}(s) = \frac{\ln P_{\text{LM}}(s) - \ln P_{\text{uni}}(s)}{|s|} \quad (12)$$

O numerador confronta dois termos. O primeiro corresponde ao modelo sensível ao contexto, aqui um bigrama; o segundo, ao mesmo texto sob modelo que ignora a ordem:

$$\ln P_{\text{LM}}(s) = \sum_{i=1}^{|s|} \ln P(w_i | w_{i-1}) \quad \ln P_{\text{uni}}(s) = \sum_{i=1}^{|s|} \ln P(w_i) \quad (13)$$

A subtração isola a contribuição da estrutura. Caso a ordem não veiculasse informação, os dois termos coincidiriam e o SLOR seria nulo. O sinal é, por consequência, interpretável: valor positivo indica que a ordem acrescenta probabilidade, ao passo que valor negativo indica sequência anti-estrutural, prevista com maior acerto sob amostragem independente das palavras.

As estimativas derivam de contagens em corpus, sem recurso a modelo treinado:

$$P(w) = \frac{c(w) + 1}{N + V} \quad P(w_i | w_{i-1}) = \lambda \frac{c(w_{i-1}, w_i)}{c(w_{i-1})} + (1 - \lambda) P(w_i) \quad (14)$$

Os termos $+1$ e $+V$ constituem a suavização de Laplace, que impede que uma palavra nunca observada anule a estimativa. A interpolação por λ resolve o problema análogo no bigrama: quando o par (w_{i-1}, w_i) não foi observado, a estimativa recua para a distribuição unigrama. Adotou-se $\lambda = 0,7$ sobre o mac_morpho, com 1.012.661 palavras distribuídas em 51.115 frases.

O método devolve um número por frase, sem indicação de posição. A Tabela 4 apresenta o resultado sobre o par de ordem.

Frase	SLOR
Há três dias o incêndio atingiu uma área de mata nativa	+1,694
nativa uma incêndio há mata de o área três atingiu dias	-1,000

Tabela 4: O SLOR sobre a frase de referência e sua permutação.

As duas frases apresentam exatamente as mesmas palavras. O termo $\ln P_{\text{uni}}$ é idêntico em ambas, valendo $-81,95$, uma vez que a distribuição unigrama ignora a ordem. A totalidade da diferença reside no primeiro termo, que é precisamente a grandeza que o SLOR foi construído para isolar, e o sinal comporta-se conforme previsto: positivo na frase bem ordenada, negativo na embaralhada.

3.5 PLL — pseudo-log-verossimilhança

O SLOR estima a probabilidade sob um modelo causal, restrito ao contexto à esquerda. Um modelo mascarado dispõe de ambos os lados: suprime-se uma palavra e consulta-se o modelo sobre o valor esperado naquela posição, com a totalidade da frase remanescente disponível. A pseudo-log-verossimilhança soma essas respostas, uma por posição:

$$\text{PLL}(s) = \sum_{i=1}^{|s|} \ln P_{\text{MLM}}(s_i \mid s_{\setminus i}) \quad (15)$$

em que $s_{\setminus i}$ designa a frase com a posição i substituída pela marca [MASK]. Cada parcela exige uma passagem pelo modelo, de modo que uma frase de n palavras demanda n inferências. Empregou-se o BERTimbau *base cased* (Souza; Nogueira; Lotufo, 2020).

O qualificativo *pseudo* é literal, e não ressalva notacional. As $|s|$ parcelas se sobrepõem, pois cada uma pressupõe corretas todas as demais posições. A soma, portanto, não corresponde a $\ln P(s)$: não há regra de cadeia que a produza, e ela não integra 1 sobre o espaço das frases. Decorre daí que o valor absoluto carece de significado, e apenas comparações são interpretáveis.

A soma é grandeza extensiva, pois cada posição acrescenta uma parcela negativa e o escore decresce com o comprimento ainda que a frase seja bem formada; a comparação de frases de extensões distintas pela soma mensura sobretudo a extensão. Adota-se, por isso, a média, que é intensiva e torna a medida homogênea ao SLOR, igualmente dividido por $|s|$:

$$\overline{\text{PLL}}(s) = \frac{1}{|s|} \sum_{i=1}^{|s|} \ln P_{\text{MLM}}(s_i \mid s_{\setminus i}) \quad (16)$$

Confrontando as duas medidas sob a mesma forma, evidencia-se a diferença que determina o emprego de cada uma:

$$\text{SLOR}(s) = \frac{\ln P_{\text{LM}}(s) - \overbrace{\ln P_{\text{uni}}(s)}^{\text{referência}}}{|s|} \quad \overline{\text{PLL}}(s) = \frac{\ln P_{\text{MLM}}(s) - \overbrace{0}^{\text{nenhuma}}}{|s|} \quad (17)$$

O PLL não subtrai referência alguma. Trata-se da mesma forma com a linha de base anulada, e essa ausência constitui simultaneamente sua vantagem — nada há a estimar a partir de contagens — e sua limitação.

O método devolve um número por frase. A Tabela 5 apresenta o resultado sobre o par mínimo de concordância verbal.

Frase	Soma	$\overline{\text{PLL}}$
Há três dias o incêndio atingiu uma área de mata nativa.	-9,16	-0,763
Há três dias os incêndios atingiu uma área de mata nativa.	-15,16	-1,263

Tabela 5: O PLL sobre o par mínimo de concordância verbal ($|s| = 12$ em ambas).

A separação é nítida, e a queda concentra-se em uma única posição: a palavra **atingiu** passa de $-0,91$ na versão correta para $-6,09$ na versão com desvio. Manifesta-se aqui a bidirecionalidade do modelo, uma vez que, ao mascarar o verbo, ele dispõe de *os incêndios* à esquerda e conclui pela inadequação do singular.

3.6 Teste do núcleo predicativo

Toda frase requer um predicado. Não se trata de heurística nem de tendência estatística, mas de propriedade sintática, e em uma árvore de dependências essa propriedade é verificável em um único ponto: a raiz, que por construção é o nó do qual todos os demais dependem.

Seja $\rho(s)$ a raiz da árvore e $\text{filhos}(\rho)$ seus dependentes diretos. A frase possui predicado quando

$$\text{Pred}(s) = \underbrace{[\text{pos}(\rho) \in \{\text{VERB}, \text{AUX}\}]}_{\text{predicado verbal}} \vee \underbrace{[\exists c \in \text{filhos}(\rho) : \text{dep}(c) = \text{cop}]}_{\text{predicado nominal}} \quad (18)$$

Duas linhas de código e um único nó inspecionado bastam, o que faz deste o método de menor custo entre os onze e ainda assim produz veredito binário e localizado.

A inspeção recai sobre a raiz, e não sobre a presença de verbo, porque o teste ingênuo — verificar se existe algum verbo na frase — aprova o fragmento. Confrontem-se *O incêndio atingiu a mata nativa* e *O incêndio que atingiu a mata nativa*: ambas contêm o verbo **atingiu**, mas a primeira constitui oração e a segunda não. O que difere não é a presença do verbo, e sim sua posição na árvore, pois o pronome **que** o rebaixa a oração relativa (**acl:relcl**) e promove o substantivo à raiz. Uma única palavra converte oração em fragmento, e apenas a estrutura registra o fato.

O segundo termo da disjunção é igualmente necessário. Em predicções nominais, como *O carro é azul*, a raiz é o predicativo **azul**, etiquetado **ADJ**, e o verbo é figura como dependente com função **cop**. Na ausência dessa cláusula, toda construção copular seria classificada como fragmento, o que inviabilizaria o método em português.

O método devolve um veredito binário acompanhado do nó que o justifica, conforme a Tabela 6.

Frase	Raiz	Classe	Veredito
Há três dias o incêndio atingiu uma área...	atingiu	VERB	ORAÇÃO
Há três dias o incêndio que atingiu uma área...	dias	NOUN	FRAGMENTO
O incêndio é intenso.	intenso	ADJ + cópula	ORAÇÃO

Tabela 6: O teste da raiz sobre três frases do corpus.

A segunda linha corresponde ao fragmento, e a terceira exercita a cláusula da cópula: a raiz é um adjetivo, o primeiro termo da disjunção é falso, e ainda assim a frase é corretamente aprovada. O método mensura completude, e nada além disso, não estabelecendo nada quanto à correção ou à plausibilidade da frase.

3.7 Índices de complexidade sintática

Os métodos anteriores investigavam a correção da frase. Este investiga outra propriedade, o grau de elaboração da construção, e o resultado que produz não é um veredito, mas um perfil numérico. Três índices se extraem da mesma árvore.

O primeiro é a profundidade máxima, definida como a distância do nó mais afastado até a raiz,

$$\text{prof}(s) = \max_{t \in s} d(t, \rho) \quad (19)$$

em que $d(t, \rho)$ designa o número de arcos percorridos de t até a raiz. O índice mensura encaixamento, isto é, o número de níveis de subordinação acumulados pela frase.

O segundo é o número de orações, obtido pela contagem dos nós que encabeçam oração, a principal e as subordinadas:

$$\text{orac}(s) = |\{t \in s : \text{dep}(t) \in \mathcal{C}\}|, \quad \mathcal{C} = \{\text{ROOT}, \text{ccomp}, \text{xcomp}, \text{advcl}, \text{acl}, \text{acl:relcl}, \text{csubj}\} \quad (20)$$

O terceiro é a ramificação média, o número médio de filhos por nó:

$$\text{ramif}(s) = \frac{1}{n} \sum_{t \in s} |\text{filhos}(t)| \quad (21)$$

A finalidade destes índices é a comparação de registros — o jurídico e o jornalístico —, a estimativa de dificuldade de leitura e a caracterização autoral. Trata-se de medidas de estilo e de carga de processamento, e não de correção: uma frase de elevada complexidade não é por isso incorreta, e uma frase incorreta pode ser trivialmente simples.

O corpus contém duas frases de exatamente 13 palavras e estruturas maximamente distintas. A primeira constitui lista plana, com um verbo e cinco irmãos dele dependentes; a segunda encaixa duas relativas, uma no interior da outra. A Tabela 7 apresenta os três índices sobre ambas.

Frase	n	prof	orac	ramif
O incêndio devastou mata, cerrado, pasto, encosta e vale.	13	3	1	0,9231
O incêndio que atingiu a mata que cercava o vale enfim cessou.	13	6	3	0,9231

Tabela 7: Os três índices sobre duas frases de mesmo comprimento.

A profundidade e o número de orações separam as duas frases com margem ampla: o encaixamento duplica e a contagem de orações triplica, sem alteração do comprimento. É o comportamento esperado de um índice de complexidade, a saber, capturar a forma da árvore independentemente do número de palavras que a compõem, e nenhum dos métodos anteriores distingue essas duas frases, uma vez que ambas são corretas. A terceira coluna, contudo, é idêntica nas duas, e a Seção 4 examina a razão disso.

3.8 Comprimento de dependência e não-projetividade

Os métodos anteriores examinavam quais palavras se vinculam a quais. Este examina a distância que as separa na ordem linear e a eventual sobreposição entre os vínculos. São duas medidas extraídas da mesma árvore, ambas operando sobre apenas duas informações — o conjunto de arcos e a posição de cada palavra —, sem que intervenham etiquetas, morfologia ou léxico.

A primeira é o comprimento de dependência. Cada palavra t , exceto a raiz, vincula-se ao seu núcleo $h(t)$; sendo $i(\cdot)$ a posição na frase, o arco apresenta comprimento $d(t) = |i(t) - i(h(t))|$, e a soma sobre a frase integral fornece

$$D(s) = \sum_{t \neq \rho} d(t) \quad \bar{D}(s) = \frac{D(s)}{|A|} \quad (22)$$

em que $|A|$ designa o número de arcos, excluída a pontuação. Uma vez que D cresce com a extensão da frase, apenas $\bar{D}$ é comparável entre frases de comprimentos diferentes.

A justificativa da medida é de ordem cognitiva. Um arco vincula duas palavras cuja relação é necessária à interpretação; ao processar a primeira, o leitor mantém o vínculo em aberto até encontrar a segunda, e quanto maior o arco, maior o intervalo de retenção. É a hipótese da minimização do comprimento de dependência (Gibson, 1998; Liu, 2008), para a qual há evidência em larga escala em dezenas de línguas (Futrell; Mahowald; Gibson, 2015).

A segunda medida é a não-projetividade. Tomem-se dois arcos, cada um representado com a extremidade de menor índice em primeiro lugar, (i, j) e (k, l) , com $i < j$ e $k < l$. Os arcos se cruzam quando exatamente uma extremidade de cada um recai no interior do outro:

$$i < k < j < l \quad \text{ou} \quad k < i < l < j \quad (23)$$

Sendo $X(s)$ o total de pares que se cruzam, a árvore é projetiva quando $X(s) = 0$, isto é, quando é possível traçar todos os arcos acima da linha sem sobreposição entre eles. A condição é puramente aritmética sobre índices, não comportando elemento linguístico algum.

O corpus contém duas frases com as mesmas 13 palavras e os mesmos 12 arcos, ambas corretas, diferindo apenas na ordem. A Tabela 8 apresenta as duas medidas sobre elas.

Frase	D	$\bar{D}$	Maior arco	X
O vento agravou a seca que intensificou o fogo que destruiu a mata.	17	1,42	2	0
O fogo que a seca que o vento agravou intensificou destruiu a mata.	43	3,58	9	0

Tabela 8: As duas medidas sobre o mesmo conteúdo em ordens distintas.

Na primeira frase nenhum arco excede 2, pois cada relativa se vincula ao substantivo imediatamente anterior e a frase se resolve da esquerda para a direita sem retenção. Na segunda os vínculos se acumulam — **fogo** encontra seu verbo nove posições adiante — e $\bar{D}$ mais que duplica. Como referência aproximada, a prosa comum em português situa-se entre 1 e 2; acima de 3, a frase mantém número elevado de vínculos simultaneamente em aberto.

Este é o aspecto inacessível aos índices da subseção anterior. Ambas as frases encaixam duas relativas e receberiam a mesma profundidade e o mesmo número de orações, de modo que o que as distingue é a posição em que as relativas foram inseridas. Já X é nulo em ambas, como ocorre na quase totalidade dos casos, o que a Seção 4 retoma.

3.9 Surpresa por token

O SLOR e o PLL devolvem um valor para a frase integral. Prestam-se à ordenação de frases, mas não localizam o desvio. A surpresa devolve um valor por palavra: é a mesma grandeza, examinada antes da agregação.

Para cada posição, a surpresa é o logaritmo negativo da probabilidade que o modelo atribui à palavra efetivamente ocorrente:

$$\text{surp}(w_i) = -\ln P(w_i \mid w_{i-1}) \quad (24)$$

Como $P \in (0, 1]$, o logaritmo é negativo e a surpresa é sempre não negativa. Assume valor nulo sob certeza do modelo e cresce ilimitadamente à medida que a palavra se torna improvável. A unidade é relevante: em logaritmo natural a grandeza é expressa em *nats* e, sob $\log_2$, em *bits*, caso em que a leitura é literal — a quantidade de informação que a palavra veicula. A surpresa corresponde exatamente à autoinformação da teoria da informação.

O método não constitui técnica nova, mas a parcela que o SLOR já agregava. Retomando os dois estimadores da subseção 3.4,

$$\text{SLOR}(s) = \frac{1}{|s|} \sum_i [\text{surp}_{\text{uni}}(w_i) - \text{surp}_{\text{bi}}(w_i)] \quad (25)$$

isto é, o SLOR é a média da redução de surpresa produzida pelo contexto. Este método é o mesmo cálculo exposto antes da agregação, de modo que nada é recomputado e nenhum modelo adicional se faz necessário.

A leitura proposta consiste em identificar o pico,

$$\hat{i} = \arg \max_i \text{surp}(w_i) \quad (26)$$

sob a expectativa de que a surpresa se eleve na posição defeituosa, o que permitiria localizar a palavra. Convém registrar a suposição embutida nessa leitura: assume-se que *improvável* e *incorreto* coincidam.

O método devolve um perfil com um valor por palavra, do qual se retém o pico. A Tabela 9 apresenta o resultado sobre três frases.

Frase	Pico	Palavra
Há três dias o incêndio atingiu uma área de mata nativa	11,47	atingiu
Há três dias o incêndio cantou uma área de mata nativa	13,70	cantou
Focos recorrentes apresentaram persistência anômala	15,08	anômala

Tabela 9: O pico de surpresa em três frases, em nats.

Nas posições em que o contexto efetivamente intervém, a leitura é adequada. Isoladamente, **nativa** é palavra de frequência muito baixa, com surpresa de 11,58; na sequência de **mata**, contudo, é praticamente esperada e o valor decresce para 3,53. É o comportamento pretendido pela técnica, a saber, mensurar a palavra em posição, e não em abstrato. As duas outras linhas da tabela, entretanto, correspondem a frases corretas, e a Seção 4 examina o que o $\arg \max$ está de fato selecionando.

3.10 Plausibilidade do verbo mascarado

Os métodos anteriores atribuem escore ao que está escrito. Este inverte o procedimento: suprime-se a palavra e determina-se qual palavra seria esperada naquela posição, confrontando o texto com a expectativa apenas em seguida.

A supressão de posição arbitrária não seria adequada, e a escolha é sintática: suprime-se a raiz da árvore de dependências, isto é, o verbo que sustenta a predicação e seleciona os demais argumentos. O método só se aplica quando $\text{pos}(\rho(s)) = \text{VERB}$ e, quando essa condição é falsa — fragmento ou predicação nominal —, a resposta adequada é **n/a**, e não um escore. Não se trata de limitação implícita, mas de elemento constitutivo da definição. Cabe observar o arranjo: o analisador sintático determina a posição a ser consultada, e o modelo estatístico determina o que é plausível naquela posição, sendo que nenhum dos dois executaria a tarefa isoladamente.

Substituída a raiz pela marca, obtém-se $s_{\setminus \rho}$, e o modelo devolve uma distribuição sobre todo o vocabulário $\mathcal{V}$, que soma 1. Diferentemente do PLL, trata-se de probabilidade em sentido estrito, uma vez que a soma percorre as alternativas de uma única posição, que é exatamente o que o modelo mascarado foi treinado para prever. Dela se extraem duas leituras, o logaritmo da probabilidade do verbo escrito e a margem até o melhor preenchimento possível:

$$\hat{v} = \arg \max_{v \in \mathcal{V}} P(v \mid s_{\setminus \rho}) \quad m(s) = \ln P(\hat{v} \mid s_{\setminus \rho}) - \ln P(v_{\rho} \mid s_{\setminus \rho}) \quad (27)$$

Por construção $m(s) \geq 0$, e $m(s) = 0$ exatamente quando o verbo escrito é a primeira escolha do modelo.

Adota-se a margem, e não o valor absoluto, porque este depende do grau geral de previsibilidade da posição: em contexto muito restrito toda alternativa recebe probabilidade elevada e, em contexto vago, toda alternativa recebe probabilidade baixa, inclusive o verbo adequado. A margem normaliza pelo máximo daquela posição, quantificando a distância ao melhor preenchimento em lugar da probabilidade absoluta.

O método devolve a margem, acompanhada da lista das formas esperadas, conforme a Tabela 10.

Frase	$\ln P$ (escrito)	Margem
Há três dias o incêndio destruiu uma área de mata nativa.	-0,72	0,00
Há três dias o incêndio atingiu uma área de mata nativa.	-0,91	0,20
Há três dias o incêndio cantou uma área de mata nativa.	-14,45	13,73

Tabela 10: A margem do verbo da raiz. As formas esperadas são as mesmas nas três frases: [destruiu, atingiu, atinge, invadiu, em].

A separação é ampla, com quase 14 nats entre o verbo adequado e o anômalo e os dois verbos plausíveis situados junto ao zero. O aspecto metodologicamente relevante é a lista de formas esperadas ser idêntica nas três frases, o que não poderia ser diferente: ao mascarar a raiz, supprime-se justamente a única palavra em que as frases diferem, de modo que o contexto remanescente é o mesmo. O instrumento de medida permanece fixo e apenas o objeto mensurado varia, e é essa condição que torna a comparação legítima.

A primeira linha exibe o piso da medida. A forma **destruiu** é a primeira escolha do modelo, razão pela qual a margem é exatamente nula, o que confere significado ao zero da escala. Nos casos em que a raiz não é verbo, como no fragmento e na predicação nominal do corpus, a resposta é **n/a**, e o reconhecimento da não aplicabilidade integra o emprego correto do método.

3.11 Embeddings

Todos os métodos anteriores tratam a palavra como símbolo: ela pertence ou não ao léxico, casa ou não com a regra, possui ou não contagem no corpus, e duas palavras distintas são simplesmente distintas, sem gradação. Este método substitui o símbolo por um ponto no espaço, obtendo com isso uma noção de proximidade ausente nos demais.

O fundamento é a hipótese distribucional, segundo a qual palavras que ocorrem nos mesmos contextos possuem significados relacionados (Mikolov *et al.*, 2013). O vetor é construído de modo a sumarizar os contextos de ocorrência da palavra no corpus de treino, e o resultado é uma tabela $\mathbf{v} : \mathcal{V} \rightarrow \mathbb{R}^d$ com uma linha por palavra, aqui com $d = 300$ e 20.000 linhas. Trata-se de consulta, e não de cálculo, uma vez que o vetor de cada palavra é invariante e está armazenado no modelo. Desta propriedade decorrem tanto os acertos quanto os limites do método: o vetor não codifica o significado da palavra, mas os contextos em que ela habitualmente ocorre.

A comparação é feita pelo cosseno, isto é, pelo ângulo entre os dois vetores:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \quad (28)$$

O valor situa-se entre -1 e $+1$, assumindo 1 quando os vetores apontam na mesma direção e 0 quando são ortogonais. Emprega-se o cosseno, e não a distância euclidiana, porque a norma $\|\mathbf{v}\|$ veicula sobretudo frequência, dado que palavras comuns tendem a vetores de maior comprimento; a divisão pelas duas normas descarta essa magnitude e retém apenas a direção, onde reside a informação contextual.

A extensão mais simples da medida para a frase é a média dos vetores de suas palavras:

$$\mathbf{v}(s) = \frac{1}{|s|} \sum_{t \in s} \mathbf{v}(t) \quad (29)$$

O somatório percorre um multiconjunto, de modo que qualquer reordenação da frase apresenta exatamente os mesmos termos e, por consequência, a mesma soma. A Seção 4 examina o que daí decorre.

O método devolve um número entre -1 e $+1$ por par de palavras, conforme a Tabela 11.

Par	Relação	cos
seco × úmido	antônimos	+0,838
quente × frio	antônimos	+0,690
área × região	sinônimos	+0,658
chamas × fogo	sinônimos	+0,648
mata × floresta	sinônimos	+0,610
início × fim	antônimos	+0,562
incêndio × fogo	sinônimos	+0,509
ativo × extinto	antônimos	+0,263
fogo × sintaxe	sem relação	+0,065
incêndio × gramática	sem relação	+0,005
área × advérbio	sem relação	−0,063

Tabela 11: Cossenos entre pares de palavras do domínio, ordenados por proximidade.

O bloco inferior estabelece a referência de leitura, uma vez que o zero corresponde à ausência de relação e é contra ele que os demais valores devem ser interpretados. A ordenação do bloco superior constitui o resultado do método sobre o corpus, e a Seção 4 a discute (Faruqui *et al.*, 2016; Schnabel *et al.*, 2015).

4 Resultados

Tendo em vista que os melhores resultados foram obtidos com o léxico, com os dois métodos apoiados no analisador sintático e com o modelo mascarado, os demais não foram incorporados à cadeia. Os descritores — índices de complexidade sintática, comprimento de dependência e embeddings — não respondem à pergunta da correção, uma vez que medem estilo, custo de processamento e proximidade temática, e as frases que os separam no corpus são todas corretas. Os escores globais, SLOR e PLL, exigem um termo de comparação de que a avaliação de uma frase isolada não dispõe, e o SLOR degenera ainda fora do vocabulário do corpus de contagens. A surpresa por token, por sua vez, foi excluída por medição direta: seu pico recaiu sobre o verbo correto da frase de referência.

Aos quatro métodos selecionados incorporaram-se três ajustes identificados nas subseções anteriores: a exigência de verbo finito na raiz, a comparação de gênero no particípio passivo e o tratamento do numeral por valor, dado que o numeral não porta traço de número.

Seguindo as etapas lógicas da avaliação, da ortografia à semântica, obtém-se a ordem devida da cadeia. A verificação ortográfica ocupa a primeira posição por constituir o único veredito exato e porque uma palavra fora do léxico não permanece contida nessa etapa: ela deforma a árvore de dependências e, com ela, as duas etapas que a leem. A verificação estrutural antecede a semântica porque o método do verbo mascarado devolve **n/a** quando a raiz não é um verbo; a existência de predicado constitui, portanto, pré-requisito da etapa seguinte, e o teste da raiz a verifica a custo desprezível.

Cada etapa devolve um conjunto de achados, e o veredito resulta da união

$$\text{Loc}(s) = E_1(s) \cup E_2(s) \cup E_3(s) \cup E_4(s) \quad \text{Loc}(s) \neq \emptyset \implies \text{frase reprovada} \quad (30)$$

O veredito decorre, portanto, da vacuidade de um conjunto: nenhum valor é somado, ponderado ou confrontado com limiar agregado. A cadeia dispõe de um único parâmetro calibrável, o θ da etapa semântica, fixado em 5,0 nats, e ele determina apenas a admissão daquele achado, sem participar do veredito final. As três primeiras etapas decidem por pertinência a um conjunto ou por igualdade de valores, sem parâmetro algum.

Percurso da cadeia sobre uma frase

Aplica-se a seguir a cadeia, etapa a etapa, à frase *Há tres dias o incêndio atingiu uma áreas de mata natvia*, que reúne três desvios de naturezas distintas. Todas as quatro etapas são executadas, ainda que a primeira produza achado.

A etapa inicial avalia a pertinência ao léxico, resguardados os nomes próprios e os numerais:

$$E_1(s) = \{ t : \ell(t) \notin D, \text{ pos}(t) \neq \text{PROP}, \ell(t) \notin \mathbb{N} \} \quad (31)$$

O predicado é avaliado sobre uma palavra por vez, contra o conjunto. Das onze palavras, dez pertencem a D e apenas **natvia** não, donde $E_1(s) = \{\text{natvia}\}$. Cabe registrar a segunda palavra: a forma **tres**, sem acento, **pertence** ao léxico, com $f = 1.690$ ocorrências, uma vez que a lista de frequências foi construída a partir de texto autêntico da web, em que a grafia sem acento ocorre com frequência suficiente para ser incorporada. A etapa não produz achado nessa posição, e não por defeito de implementação: trata-se do comportamento previsto pela fórmula, em que D constitui a definição operacional de erro.

Para o achado detectado, a segunda parte do método computa os candidatos e resolve o desempate por frequência:

$$C(\text{natvia}) = \{\text{nativa}, \text{naevia}, \text{natia}, \text{latvia}\} \quad \hat{w} = \arg \max_{c \in C} f(c) = \text{nativa} \quad (f = 912) \quad (32)$$

A segunda etapa verifica a existência de predicado, já sob a exigência de finitude:

$$\begin{aligned} \text{pred}(s) \iff & [\text{pos}(\rho) \in \{\text{VERB}, \text{AUX}\} \wedge \text{VerbForm}(\rho) = \text{Fin}] \\ & \vee [\exists c \in \text{apoio}(\rho) : \text{VerbForm}(c) = \text{Fin}] \end{aligned} \quad (33)$$

Não há percurso a executar, dado que se inspeciona um único nó. A raiz é **atingiu**, com $\text{pos} = \text{VERB}$ e $\text{VerbForm} = \text{Fin}$, e não há auxiliar nem cópula. Satisfeita a primeira cláusula, a segunda não é avaliada, e $E_2(s) = \emptyset$.

A terceira etapa percorre os arcos e desdobra cada um nos traços exigidos por $T(r)$. Dos dez arcos da frase, apenas três são admitidos, pois nos demais $T(r) = \emptyset$: as palavras **de**, **mata** e **áreas** vinculam-se por **case**, **nmod** e **obj**, e nenhuma dessas relações impõe concordância. A Tabela 12 apresenta as comparações efetuadas.

Arco (t, r, h)	τ	$\hat{\mu}_\tau(t)$	$\hat{\mu}_\tau(h)$	Resultado
(o, det, incêndio)	Number	Sing	Sing	iguais
	Gender	Masc	Masc	iguais
(incêndio, nsubj, atingiu)	Number	Sing	Sing	iguais
	Person	$\perp$	3	comparação suprimida
(uma, det, áreas)	Number	Sing	Plur	$\in E_3(s)$
	Gender	Fem	Fem	iguais

Tabela 12: As comparações da etapa gramatical sobre os três arcos admitidos.

A quarta linha exemplifica a guarda $\hat{\mu}_\tau(\cdot) \neq \perp$: o substantivo **incêndio** não porta traço de pessoa, ao passo que o verbo apresenta **Person** = 3, de modo que a comparação é suprimida. O resultado não é de igualdade, mas de ausência de termos a comparar. Resta, portanto, $E_3(s) = \{(\text{uma}, \text{áreas}, \text{Number})\}$.

A quarta etapa inspeciona uma única posição, a da raiz, mascarando-a e comparando a distribuição obtida com a palavra escrita:

$$m = \ln P(\hat{v} \mid s_{\setminus \rho}) - \ln P(v_\rho \mid s_{\setminus \rho}) \quad (34)$$

Mascarada a raiz, o modelo devolve como formas esperadas [destruiu, atingiu, invadiu, atinge, em], nas quais o verbo escrito ocupa a segunda colocação, com margem $m = 0,95$. Como $m < \theta = 5,0$, tem-se $E_4(s) = \emptyset$. Manifesta-se aqui o único limiar de toda a cadeia: as três etapas anteriores decidem por pertinência a um conjunto ou por igualdade de valores, ao passo que esta compara um valor real a um ponto de corte, e θ constitui escolha do analista.

Reunindo os quatro conjuntos,

$$\text{Loc}(s) = \underbrace{\{\text{natvia}\}}_{E_1} \cup \underbrace{\emptyset}_{E_2} \cup \underbrace{\{(\text{uma}, \text{áreas})\}}_{E_3} \cup \underbrace{\emptyset}_{E_4} \neq \emptyset \quad (35)$$

donde a frase é reprovada, com dois achados, cada qual identificando as palavras envolvidas e a etapa de origem.

Propagação de erro entre etapas

A Tabela 13 consolida o laudo dessa frase ao lado do de uma variante que contém apenas o desvio de concordância.

Etapa	...	uma áreas de mata natvia.	Há tres dias ... uma áreas ... natvia.
ortografia	ok	—	!! natvia → natvia
estrutura	ok	predicado presente	ok predicado presente [†]
gramática	!!	uma(Sing) × áreas(Plur)	!! uma(Sing) × áreas(Plur) [†]
semântica	ok	margem 0,65	ok margem 0,95

Tabela 13: Laudo de duas frases. [†] marcado como *árvore sob suspeita*.

A decisão de não bloquear tem consequência observável. A palavra **natvia** não permanece contida na etapa inicial: ela deforma a árvore que as etapas seguintes leem, conforme a Tabela 14.

Arco produzido	Efeito observado
(tres, obj, Há)	tres analisado como objeto de Há
(dias, flat:name, tres)	tres dias lido como nome próprio composto
(natvia, dep, atingiu)	dep é o rótulo de relação não classificável

Tabela 14: Arcos deformados pela palavra fora do léxico.

Registra-se por isso a marcação *árvore sob suspeita* nas duas etapas que leem a árvore, marcação que não indica incorreção, mas menor confiabilidade. No caso examinado a deformação não atingiu o arco relevante, e o achado de concordância é legítimo, o que constitui, contudo, contingência posicional e não garantia.

Duas lacunas, de naturezas distintas, delimitam o alcance da cadeia. A primeira é a escolha lexical: *A três dias* atravessa as quatro etapas sem detecção, pois **a** consta do léxico, é preposição e não estabelece arco de concordância, e a etapa semântica não inspeciona essa posição. Trata-se exatamente do caso que as regras escritas à mão detectam, o que torna sua integração a extensão mais imediata da cadeia. A segunda é o erro factual: *A área cresceu de 1.284 para 340 hectares* é português correto e falso apenas em relação à base que originou o texto. Nenhum método de natureza linguística alcança esse nível, uma vez que a verificação exige confrontar o texto com os campos que o geraram.

Referências

DAMERAU, Fred J. A technique for computer detection and correction of spelling errors. *Communications of the ACM*, v. 7, n. 3, p. 171–176, 1964. DOI: 10.1145/363958.363994.

FARUQUI, Manaal *et al.* Problems with evaluation of word embeddings using word similarity tasks. *In: PROCEEDINGS of the 1st Workshop on Evaluating Vector-Space Representations for NLP (RepEval)*. [S. l.: s. n.], 2016. p. 30–35.

FUTRELL, Richard; MAHOWALD, Kyle; GIBSON, Edward. Large-scale evidence of dependency length minimization in 37 languages. **Proceedings of the National Academy of Sciences**, v. 112, n. 33, p. 10336–10341, 2015. DOI: 10.1073/pnas.1502134112.

GIBSON, Edward. Linguistic complexity: locality of syntactic dependencies. **Cognition**, v. 68, n. 1, p. 1–76, 1998. DOI: 10.1016/S0010-0277(98)00034-1.

KUKICH, Karen. Techniques for automatically correcting words in text. **ACM Computing Surveys**, v. 24, n. 4, p. 377–439, 1992. DOI: 10.1145/146370.146380.

LAU, Jey Han; CLARK, Alexander; LAPPIN, Shalom. Grammaticality, acceptability, and probability: a probabilistic view of linguistic knowledge. **Cognitive Science**, v. 41, n. 5, p. 1202–1241, 2017. DOI: 10.1111/cogs.12414.

LEVENSHTEIN, Vladimir I. Binary codes capable of correcting deletions, insertions and reversals. **Soviet Physics Doklady**, v. 10, n. 8, p. 707–710, 1966.

LIU, Haitao. Dependency distance as a metric of language comprehension difficulty. **Journal of Cognitive Science**, v. 9, n. 2, p. 159–191, 2008.

MIKOLOV, Tomas *et al.* Distributed representations of words and phrases and their compositionality. *In: ADVANCES in Neural Information Processing Systems (NIPS)*. [S. l.: s. n.], 2013. v. 26, p. 3111–3119.

MŁKOWSKI, Marcin. Developing an open-source, rule-based proofreading tool. **Software: Practice and Experience**, v. 40, n. 7, p. 543–566, 2010. DOI: 10.1002/spe.971.

NABER, Daniel. **A rule-based style and grammar checker**. 2003. Diplomarbeit – Universität Bielefeld.

NIVRE, Joakim *et al.* Universal Dependencies v1: a multilingual treebank collection. *In: PROCEEDINGS of the 10th International Conference on Language Resources and Evaluation (LREC)*. [S. l.: s. n.], 2016. p. 1659–1666.

PAULS, Adam; KLEIN, Dan. Large-scale syntactic language modeling with treelets. *In: PROCEEDINGS of the 50th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S. l.: s. n.], 2012. p. 959–968.

RADEMAKER, Alexandre *et al.* Universal Dependencies for Portuguese. *In: PROCEEDINGS of the Fourth International Conference on Dependency Linguistics (Depling)*. [S. l.: s. n.], 2017. p. 197–206.

SALAZAR, Julian *et al.* Masked language model scoring. *In: PROCEEDINGS of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S. l.: s. n.], 2020. p. 2699–2712. DOI: 10.18653/v1/2020.acl-main.240.

SCHNABEL, Tobias *et al.* Evaluation methods for unsupervised word embeddings. *In: PROCEEDINGS of the 2015 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. [S. l.: s. n.], 2015. p. 298–307.

SOUZA, Fábio; NOGUEIRA, Rodrigo; LOTUFO, Roberto. BERTimbau: pretrained BERT models for Brazilian Portuguese. *In: PROCEEDINGS of the 9th Brazilian Conference on Intelligent Systems (BRACIS)*. [S. l.: s. n.], 2020. p. 403–417. DOI: 10.1007/978-3-030-61377-8_28.

WANG, Alex; CHO, Kyunghyun. BERT has a mouth, and it must speak: BERT as a Markov random field language model. *In: PROCEEDINGS of the Workshop on Methods for Optimizing and Evaluating Neural Language Generation (NeuralGen)*. [S. l.: s. n.], 2019. p. 30–36.