

Métodos de avaliação de frases em português e resultados em pipeline

Matheus Sales

Resumo

Dada uma frase isolada, sem gabarito e sem referência, coloca-se a questão de quanto se pode afirmar automaticamente a respeito de sua boa formação. Este trabalho levanta métodos de avaliação aplicáveis ao português brasileiro analisando: léxicos, gramáticas de padrões, analisadores sintáticos, modelos de n -grama, modelos mascarados e vetores distribucionais. Descreve cada um sob um formalismo único e submete todos a um mesmo conjunto controlado de pares mínimos. A caracterização mostra que os métodos não são intercambiáveis nem ordenáveis por qualidade: suas coberturas são complementares. Dos métodos são selecionados os com melhores resultados e compõe-se uma *pipeline* de quatro etapas, cuja ordem decorre das propriedades medidas e cujo veredito resulta da vacuidade de um conjunto de achados localizados, com um único parâmetro calibrável em toda a cadeia. Reportam-se os resultados da pipeline sobre o mesmo corpus, incluindo a propagação de erro entre etapas e os tipos de desvio que ela não alcança.

Palavras-chave: avaliação automática de frases; pares mínimos; aceitabilidade linguística; análise de dependências; língua portuguesa.

1 Introdução

A avaliação automática de uma frase isolada, sem gabarito e sem referência, constitui problema de ordem prática antes de teórica. Um sistema que redige *Há três dias o incêndio atingiu uma área de mata nativa* a partir dos campos de um registro de eventos de fogo precisa verificar o que produziu, e não dispõe de termo de comparação: não há tradução de origem nem resumo humano. Métricas que pressupõem um texto de referência, como BLEU e ROUGE, não se aplicam, e a verificação recai sobre a frase em si.

Os métodos disponíveis para essa tarefa são numerosos e heterogêneos: léxicos associados a distância de edição (Damerau, 1964; Levenshtein, 1966; Kukich, 1992), gramáticas de padrões escritos manualmente (Naber, 2003; Miłkowski, 2010), analisadores sintáticos (Nivre *et al.*, 2016; Rademaker *et al.*, 2017), modelos de linguagem dos quais derivam medidas de aceitabilidade como o SLOR (Pauls; Klein, 2012; Lau; Clark; Lappin, 2017) e a pseudo-log-verossimilhança (Wang; Cho, 2019; Salazar *et al.*, 2020), e vetores distribucionais (Mikolov *et al.*, 2013). Não respondem, contudo, à mesma pergunta: alguns produzem veredito exato, outros veredito estimado, e outros apenas um valor numérico.

Tendo em vista um sistema que gera textos sobre eventos de fogo em linguagem natural a partir apenas de informações numéricas extraídas de um banco de dados, é necessária uma metodologia parametrizada e rastreável para avaliar os textos gerados. Trata-se de um problema de múltiplas dimensões — gramática, estrutura, ortografia e semântica. em cada uma dessas dimensões.

2 Metodologia

O procedimento adotado parte de uma frase correta, modificada de forma controlada. Cada frase variante introduz um único desvio, de tipo conhecido. Todos os métodos são aplicados às mesmas frases, e observa-se o que cada um detecta, o que deixa passar e por qual mecanismo.

A frase de referência é *Há três dias o incêndio atingiu uma área de mata nativa*, redigida a partir dos campos de um registro de eventos de fogo. Dela derivam as doze variantes apresentadas na Tabela 1.

Variante	Nível afetado	Alteração introduzida
natvia	ortografia	forma inexistente no léxico
A três dias	escolha lexical	forma existente, mas inadequada
uma áreas	concordância nominal	determinante $\times$ núcleo
a área inteiro	concordância nominal	adjetivo posposto
os incêndios atingiu	concordância verbal	sujeito nominal $\times$ verbo
cantou	semântica	restrição de seleção violada
que atingiu	estrutura	relativa sem oração principal
Atingir...	estrutura	infinitivo isolado
ordem embaralhada	ordem	as onze palavras permutadas
tres + áreas + natvia	múltiplo	três desvios simultâneos
destruiu	—	paráfrase plausível (controle)
O incêndio é intenso	—	predicação nominal (controle)

Tabela 1: As doze variantes da frase de referência.

As duas últimas linhas não contêm desvio e destinam-se a verificar o inverso: um método que as acusa produz falso positivo. A forma **destruiu** constitui paráfrase igualmente correta, e *O incêndio é intenso* é predicação nominal legítima, em que o verbo não ocupa a raiz da árvore.

Quatro frases auxiliares completam o corpus. Duas comparam comprimento de dependência com as mesmas palavras em ordens distintas, e duas formam um par de permutação. São necessárias porque os descritores só se distinguem quando o comprimento é mantido fixo.

Os métodos distribuem-se por quatro dimensões, cada uma associada a uma verificação distinta. A ortografia verifica se as palavras existem; a gramática, se elas concordam entre si; a estrutura, se a frase dispõe de predicado e como suas partes se articulam; e a semântica, se o enunciado é plausível. A divisão não é apenas organizativa, uma vez que cada dimensão pressupõe a anterior: não se avalia concordância sobre uma palavra que não existe, nem plausibilidade sobre uma frase desprovida de predicado. É essa dependência que determina a ordem das etapas da *pipeline*.

Nenhum modelo foi treinado ou ajustado. Os limites observados adiante pertencem a eles, e não ao método: a substituição do analisador sintático altera o resultado sem alterar uma linha da regra.

3 Os métodos

Cada subseção apresenta um método: o que ele mede, como é definido e um exemplo mínimo que torne a definição legível. O que cada um detectou e deixou passar sobre o corpus está reunido na Seção 4.

3.1 Léxico com distância de edição

O método se propõe a duas coisas: verificar se cada palavra da frase é forma atestada do idioma e, quando não é, propor a forma que provavelmente se pretendia escrever. Opera sobre

um conjunto finito D , cada elemento associado a uma contagem $f(w)$ de ocorrências no corpus que originou a lista, e decompõe-se em dois passos encadeados (Kukich, 1992).

O primeiro é a detecção. Dado o léxico D ,

$$\text{erro}(w) = \begin{cases} 0, & w \in D \\ 1, & w \notin D \end{cases} \quad (1)$$

O predicado é exato: a palavra consta ou não consta do conjunto, sem gradação nem margem de incerteza.

O segundo é a correção, aplicada apenas às formas detectadas. Seja $C_k(w)$ o conjunto das formas do léxico situadas a exatamente k edições de w . A busca é escalonada, de modo que a distância 2 só é consultada quando a distância 1 não devolve candidato algum:

$$C(w) = \begin{cases} C_1(w), & C_1(w) \neq \emptyset \\ C_2(w), & C_1(w) = \emptyset \end{cases} \quad (2)$$

e, entre os candidatos admitidos, a frequência determina a escolha:

$$\hat{w} = \arg \max_{c \in C(w)} f(c) \quad (3)$$

A distância empregada é a de Damerau-Levenshtein (Damerau, 1964; Levenshtein, 1966), que computa a transposição de dois caracteres adjacentes como uma única edição, e não como duas. A escolha da métrica não é detalhe de implementação: é ela que determina quem entra em C_1 e, por consequência, o que o $\arg \max$ pode devolver.

3.2 Traços morfossintáticos sobre a árvore de dependências

O método se propõe a verificar concordância. A concordância não constitui heurística passível de aproximação: define-se como igualdade de traços entre dois nós ligados na árvore sintática, e o método transcreve literalmente essa definição.

O analisador (Nivre *et al.*, 2016) associa a cada palavra t três informações: a classe gramatical, o núcleo $h(t)$ do qual ela depende e um mapa de traços

$$\hat{\mu}_\tau(t) \in \{\text{valor}, \perp\} \quad (4)$$

em que τ designa o traço — **Number**, **Gender** ou **Person** — e $\perp$ indica ausência, uma vez que preposições e advérbios, entre outras classes, não portam número nem gênero. A árvore é o conjunto de arcos $A = \{(t, r, h(t))\}$, sendo r a função sintática. Emprega-se $\hat{\mu}_\tau(t)$, e não $\mu_\tau(t)$, porque o traço não é observado, mas *predito* pelo anotador — distinção notacional aqui e consequente na Seção 5, onde um traço mal predito suprime um desvio real.

Nem todo arco impõe concordância, e cada tipo impõe traços distintos. Seja $T(r)$ o conjunto de traços cuja coincidência o arco r exige:

$$T(r) = \begin{cases} \{\text{Number}, \text{Gender}\}, & r \in \{\text{det}, \text{amod}, \text{acl}\}, h(t) \text{ é NOUN/PROPN} \\ \{\text{Number}, \text{Person}\}, & r \in \{\text{nsubj}, \text{nsubj:pass}\}, h(t) \text{ é VERB/AUX} \\ \emptyset, & \text{caso contrário} \end{cases} \quad (5)$$

O conjunto de erros da frase é

$$E(s) = \{(t, h, \tau) : (t, r, h) \in A, \tau \in T(r), \hat{\mu}_\tau(t) \neq \perp, \hat{\mu}_\tau(h) \neq \perp, \hat{\mu}_\tau(t) \neq \hat{\mu}_\tau(h)\} \quad (6)$$

e a frase é aceita quando $E(s) = \emptyset$. A saída não é um escore, mas o conjunto das palavras responsáveis, cada uma acompanhada do termo com que diverge e do traço violado.

Três decisões estão inscritas na formulação. A guarda $\hat{\mu}_\tau(\cdot) \neq \perp$ é obrigatória: sem ela, toda palavra desprovida de número seria computada como discordante de seu núcleo. O terceiro caso, $T(r) = \emptyset$, previne o falso positivo mais frequente — em *as flores do jardim*, *jardim* liga-se a *flores* por **nmod**, e substantivos assim ligados não concordam entre si. E a inclusão de **acl** não é acessória: em *os dados coletados* o particípio recebe essa função e a classe VERB, e não **amod**, de modo que sua omissão suprimiria a verificação de concordância de particípio.

3.3 Regras escritas à mão

O método se propõe a confrontar a frase com a norma escrita. A gramática normativa encontra-se codificada em compêndios e gramáticas de referência, e o método não realiza inferência: cada regra é transcrita manualmente como um padrão sobre a sequência anotada, e o verificador busca casamentos (Naber, 2003; Miłkowski, 2010).

A frase é tokenizada e anotada, constituindo uma sequência de triplas

$$s = \langle (w_1, \ell_1, p_1), (w_2, \ell_2, p_2), \dots, (w_n, \ell_n, p_n) \rangle \quad (7)$$

em que w_i designa a forma escrita, ℓ_i o lema e p_i a etiqueta morfológica.

Cada regra r consiste em um padrão π_r : expressão sobre essas triplas, análoga a uma expressão regular, porém operando sobre atributos linguísticos em lugar de caracteres. A regra dispara nas posições em que o padrão casa,

$$D_r(s) = \{ i : \pi_r \text{ casa em } s \text{ a partir da posição } i \} \quad (8)$$

e a saída do método é a união sobre a gramática R , o conjunto finito de regras elaboradas para o idioma:

$$D(s) = \bigcup_{r \in R} \{ (i, r) : i \in D_r(s) \} \quad (9)$$

A propriedade determinante do método é que R é finito e de elaboração manual. Daí decorre, sem gradação intermediária,

$$\text{erro} \notin \bigcup_{r \in R} \mathcal{L}(\pi_r) \implies \text{invisível} \quad (10)$$

em que $\mathcal{L}(\pi_r)$ designa o conjunto de construções que o padrão reconhece. Não há generalização nem grau de confiança: na ausência de regra correspondente, o desvio não é detectado.

A cobertura do método equivale, portanto, ao trabalho humano investido no idioma.

3.4 SLOR — Syntactic Log-Odds Ratio (razão sintática de log-chances)

O método se propõe a separar *raro* de *incorreto*. Uma frase malformada é improvável sob um modelo de linguagem (Pauls; Klein, 2012; Lau; Clark; Lappin, 2017), o que sugeriria a leitura direta de $\ln P(s)$; a probabilidade bruta, porém, não faz essa distinção, uma vez que uma frase correta de vocabulário técnico é improvável por conter palavras improváveis, e não por má construção. O SLOR desconta a contribuição atribuível à frequência isolada das palavras e normaliza pelo comprimento:

$$\text{SLOR}(s) = \frac{\ln P_{\text{LM}}(s) - \ln P_{\text{uni}}(s)}{|s|} \quad (11)$$

O numerador confronta dois termos. O primeiro corresponde ao modelo sensível ao contexto, aqui um bigrama; o segundo, ao mesmo texto sob modelo que ignora a ordem:

$$\ln P_{\text{LM}}(s) = \sum_{i=1}^{|s|} \ln P(w_i \mid w_{i-1}) \quad \ln P_{\text{uni}}(s) = \sum_{i=1}^{|s|} \ln P(w_i) \quad (12)$$

A subtração isola a contribuição da estrutura. Sob um bigrama exato, a coincidência dos dois termos anularia o SLOR, e o sinal seria interpretável: positivo indicaria que a ordem acrescenta probabilidade, negativo indicaria sequência anti-estrutural.

As estimativas derivam de contagens em corpus, sem recurso a modelo treinado:

$$P(w) = \frac{c(w) + 1}{N + V} \quad P(w_i | w_{i-1}) = \lambda \frac{c(w_{i-1}, w_i)}{c(w_{i-1})} + (1 - \lambda) P(w_i) \quad (13)$$

Os termos $+1$ e $+V$ constituem a suavização de Laplace, que impede que uma palavra nunca observada anule a estimativa. A interpolação por λ resolve o problema análogo no bigrama: quando o par (w_{i-1}, w_i) não foi observado, a estimativa recua para a distribuição unigrama. Adotou-se $\lambda = 0,7$ sobre o mac_morpho, com $N = 1.012.661$ palavras, $V = 53.115$ formas distintas e 51.115 frases.

Desse recuo decorre uma propriedade do estimador que a definição original não possui. Quando $c(w_{i-1}, w_i) = 0$, resta $P(w_i | w_{i-1}) = (1 - \lambda)P(w_i)$, e a contribuição da posição ao numerador vale

$$\ln P(w_i | w_{i-1}) - \ln P(w_i) = \ln(1 - \lambda) = -1,204 \quad (14)$$

O piso do SLOR não é, portanto, zero, mas $\ln(1 - \lambda)$: uma frase cujos bigramas jamais foram observados recebe $-1,204$ independentemente de estar bem construída. O método devolve um número por frase, sem indicação de posição.

3.5 PLL — pseudo-log-verossimilhança

O método se propõe a avaliar cada posição da frase dispondo de todo o contexto, e não apenas do que a precede. O SLOR estima a probabilidade sob um modelo causal, restrito ao contexto à esquerda; um modelo mascarado dispõe de ambos os lados, uma vez que se suprime uma palavra e se consulta o modelo sobre o valor esperado naquela posição, com a totalidade da frase remanescente disponível. A pseudo-log-verossimilhança (Wang; Cho, 2019; Salazar *et al.*, 2020) soma essas respostas, uma por posição:

$$\text{PLL}(s) = \sum_{i=1}^{|s|} \ln P_{\text{MLM}}(s_i | s_{\setminus i}) \quad (15)$$

em que $s_{\setminus i}$ designa a frase com a posição i substituída pela marca [MASK]. Cada parcela exige uma passagem pelo modelo, de modo que uma frase de n palavras demanda n inferências. Empregou-se o BERTimbau *base cased* (Souza; Nogueira; Lotufo, 2020).

O qualificativo *pseudo* é literal, e não ressalva notacional. As $|s|$ parcelas se sobrepõem, pois cada uma pressupõe corretas todas as demais posições. A soma, portanto, não corresponde a $\ln P(s)$: não há regra de cadeia que a produza, e ela não integra 1 sobre o espaço das frases. Decorre daí que o valor absoluto carece de significado, e apenas comparações são interpretáveis.

A soma é grandeza extensiva, pois cada posição acrescenta uma parcela negativa e o escore decresce com o comprimento ainda que a frase seja bem formada. Adota-se, por isso, a média, que é intensiva e torna a medida homogênea ao SLOR, igualmente dividido por $|s|$:

$$\overline{\text{PLL}}(s) = \frac{1}{|s|} \sum_{i=1}^{|s|} \ln P_{\text{MLM}}(s_i | s_{\setminus i}) \quad (16)$$

Confrontando as duas medidas sob a mesma forma, evidencia-se a diferença que determina o emprego de cada uma:

$$\text{SLOR}(s) = \frac{\ln P_{\text{LM}}(s) - \overbrace{\ln P_{\text{uni}}(s)}^{\text{referência}}}{|s|} \quad \overline{\text{PLL}}(s) = \frac{\text{PLL}(s) - \overbrace{0}^{\text{nenhuma}}}{|s|} \quad (17)$$

O PLL não subtrai referência alguma. Trata-se da mesma forma com a linha de base anulada, e essa ausência constitui simultaneamente sua vantagem — nada há a estimar a partir de contagens — e sua limitação.

Cabe fixar a unidade de $|s|$, que difere da adotada no SLOR: a soma percorre peças do vocabulário do modelo, e não formas ortográficas. Nas frases examinadas cada forma foi preservada íntegra e, descontados [CLS] e [SEP], resulta $|s| = 12$. O método devolve um número por frase e, antes da agregação, um valor por posição.

3.6 Teste do núcleo predicativo

O método se propõe a decidir se a sequência constitui oração ou fragmento. Toda frase requer um predicado — não se trata de heurística nem de tendência estatística, mas de propriedade sintática —, e em uma árvore de dependências essa propriedade é verificável em um único ponto: a raiz, o nó que não depende de nenhum outro (Nivre *et al.*, 2016).

Seja $\rho(s)$ a raiz da árvore e $\text{filhos}(\rho)$ seus dependentes diretos. A frase possui predicado quando

$$\text{Pred}(s) = \underbrace{[\text{pos}(\rho) \in \{\text{VERB}, \text{AUX}\}]}_{\text{predicado verbal}} \vee \underbrace{[\exists c \in \text{filhos}(\rho) : \text{dep}(c) = \text{cop}]}_{\text{predicado nominal}} \quad (18)$$

A raiz e seus dependentes diretos bastam. Dada a árvore, é o método de menor custo entre os dez, e ainda assim produz veredito binário e localizado.

A inspeção recai sobre a raiz, e não sobre a presença de verbo, porque o teste ingênuo — verificar se existe algum verbo na frase — aprova o fragmento. Confrontem-se *O incêndio atingiu a mata nativa* e *O incêndio que atingiu a mata nativa*: ambas contêm o verbo **atingiu**, mas a primeira constitui oração e a segunda não. O que difere não é a presença do verbo, e sim sua posição na árvore, pois o pronome **que** o rebaixa a oração relativa (**acl:relcl**) e a raiz passa a um substantivo.

O segundo termo da disjunção é igualmente necessário. Em predicções nominais, como *O carro é azul*, a raiz é o predicativo **azul**, etiquetado **ADJ**, e o verbo **é** figura como dependente com função **cop**. Na ausência dessa cláusula, toda construção copular seria classificada como fragmento, o que inviabilizaria o método em português.

Convém registrar duas coisas que a Equação 18 não contém. Nenhum de seus termos consulta **VerbForm**, de modo que a distinção entre forma finita e infinitiva não participa do veredito. E a notação $\rho(s)$ pressupõe unicidade, que o analisador não garante. A Seção 4 mede a consequência de ambas.

3.7 Comprimento de dependência e não-projetividade

Os métodos anteriores examinavam quais palavras se vinculam a quais. Este se propõe a medir outra coisa: a distância que as separa na ordem linear e a eventual sobreposição entre os vínculos. São duas medidas extraídas da mesma árvore, ambas operando sobre apenas duas informações — o conjunto de arcos e a posição de cada palavra —, sem que intervenham etiquetas, morfologia ou léxico.

A primeira é o comprimento de dependência. Cada palavra t , exceto a raiz, vincula-se ao seu núcleo $h(t)$; sendo $i(\cdot)$ a posição na frase, o arco apresenta comprimento $d(t) = |i(t) - i(h(t))|$, e a soma sobre a frase integral fornece

$$D(s) = \sum_{t \neq \rho} d(t) \quad \bar{D}(s) = \frac{D(s)}{|A|} \quad (19)$$

em que $|A|$ designa o número de arcos, excluída a pontuação. Uma vez que D cresce com a extensão da frase, apenas $\bar{D}$ é comparável entre frases de comprimentos diferentes.

A justificativa da medida é de ordem cognitiva. Um arco vincula duas palavras cuja relação é necessária à interpretação; ao processar a primeira, o leitor mantém o vínculo em aberto até encontrar a segunda, e quanto maior o arco, maior o intervalo de retenção. É a hipótese da minimização do comprimento de dependência (Gibson, 1998; Liu, 2008), para a qual há evidência em larga escala em dezenas de línguas (Futrell; Mahowald; Gibson, 2015).

A segunda medida é a não-projetividade. Tomem-se dois arcos, cada um representado com a extremidade de menor índice em primeiro lugar, (i, j) e (k, l) , com $i < j$ e $k < l$. Os arcos se cruzam quando exatamente uma extremidade de cada um recai no interior do outro:

$$i < k < j < l \quad \text{ou} \quad k < i < l < j \quad (20)$$

Sendo $X(s)$ o total de pares que se cruzam, a árvore é projetiva quando $X(s) = 0$, isto é, quando é possível traçar todos os arcos acima da linha sem sobreposição entre eles. As desigualdades são estritas, de modo que arcos com extremidade comum não configuram cruzamento. A condição é puramente aritmética sobre índices, não comportando elemento linguístico algum.

3.8 Surpresa por token

O SLOR e o PLL devolvem um valor para a frase integral: prestam-se à ordenação, mas não localizam o desvio. Este método se propõe a localizá-lo, devolvendo um valor por palavra — é a mesma grandeza, examinada antes da agregação.

Para cada posição, a surpresa é o logaritmo negativo da probabilidade que o modelo atribui à palavra efetivamente ocorrente:

$$\text{surp}(w_i) = -\ln P(w_i \mid w_{i-1}) \quad (21)$$

Como $P \in (0, 1]$, a surpresa é sempre não negativa: assume valor nulo sob certeza do modelo e cresce à medida que a palavra se torna improvável. Em logaritmo natural a grandeza é expressa em *nats* e, sob $\log_2$, em *bits*, caso em que a leitura é literal — a quantidade de informação que a palavra veicula. A surpresa corresponde exatamente à autoinformação da teoria da informação.

O método não constitui técnica nova, mas a parcela que o SLOR já agregava. Retomando os dois estimadores da subseção 3.4,

$$\text{SLOR}(s) = \frac{1}{|s|} \sum_i [\text{surp}_{\text{uni}}(w_i) - \text{surp}_{\text{bi}}(w_i)] \quad (22)$$

isto é, o SLOR é a média da redução de surpresa produzida pelo contexto. Nada é recomputado e nenhum modelo adicional se faz necessário.

Sob esse estimador, contudo, a grandeza não cresce sem limite. Vale a mesma identidade da Equação 14: quando $c(w_{i-1}, w_i) = 0$, a interpolação recua para a unigrama e

$$\text{surp}(w_i) = -\ln[(1 - \lambda)P(w_i)] = \text{surp}_{\text{uni}}(w_i) + 1,204 \quad (23)$$

Como o Laplace impõe $P(w) \geq 1/(N + V)$, segue o teto $\text{surp}(w_i) \leq \ln(N + V) + 1,204 = 15,08$, alcançado por toda palavra ausente do corpus de contagens. Nessas posições a surpresa deixa de mensurar o contexto e passa a registrar apenas a raridade da forma.

A leitura proposta consiste em identificar o pico,

$$\hat{i} = \arg \max_i \text{surp}(w_i) \quad (24)$$

sob a expectativa de que a surpresa se eleve na posição defeituosa, o que permitiria localizar a palavra. Convém registrar a suposição embutida nessa leitura: assume-se que *improvável* e *incorreto* coincidam.

3.9 Plausibilidade do verbo mascarado

Os métodos anteriores atribuem escore ao que está escrito. Este se propõe a inverter o procedimento: suprimir a palavra, determinar qual seria esperada naquela posição e só então confrontar o texto com a expectativa.

A supressão de posição arbitrária não seria adequada, e a escolha é sintática: suprime-se a raiz da árvore de dependências, isto é, o verbo que sustenta a predicação e seleciona os demais argumentos. O método só se aplica quando $\text{pos}(\rho(s)) = \text{VERB}$ e, quando essa condição é falsa — fragmento ou predicação nominal —, a resposta adequada é **n/a**, e não um escore. Não se trata de limitação implícita, mas de elemento constitutivo da definição. Cabe observar o arranjo: o analisador sintático determina a posição a ser consultada, e o modelo estatístico determina o que é plausível naquela posição, sendo que nenhum dos dois executaria a tarefa isoladamente.

Substituída a raiz pela marca, obtém-se $s_{\setminus\rho}$, e o modelo mascarado da subseção 3.5 devolve uma distribuição sobre todo o vocabulário $\mathcal{V}$, que soma 1. Diferentemente do PLL, trata-se de probabilidade em sentido estrito, uma vez que a soma percorre as alternativas de uma única posição, que é exatamente o que o modelo mascarado foi treinado para prever. Dela se extraem duas leituras, o melhor preenchimento possível e a margem até ele:

$$\hat{v} = \arg \max_{v \in \mathcal{V}} P(v \mid s_{\setminus\rho}) \quad m(s) = \ln P(\hat{v} \mid s_{\setminus\rho}) - \ln P(v_\rho \mid s_{\setminus\rho}) \quad (25)$$

Por construção $m(s) \geq 0$, e $m(s) = 0$ exatamente quando o verbo escrito é a primeira escolha do modelo. Cabe registrar que $\mathcal{V}$ não é restrito a formas verbais: $\hat{v}$ pode ser palavra de outra classe, e a margem passaria a ser medida contra ela.

Adota-se a margem, e não o valor absoluto, porque este depende do grau geral de previsibilidade da posição: em contexto muito restrito toda alternativa recebe probabilidade elevada e, em contexto vago, toda alternativa recebe probabilidade baixa, inclusive o verbo adequado. A margem normaliza pelo máximo daquela posição, quantificando a distância ao melhor preenchimento em lugar da probabilidade absoluta. O método devolve esse número, acompanhado da lista das formas esperadas.

3.10 Embeddings

Todos os métodos anteriores tratam a palavra como símbolo: ela pertence ou não ao léxico, casa ou não com a regra, possui ou não contagem no corpus, e duas palavras distintas são simplesmente distintas, sem gradação. Este método se propõe a substituir o símbolo por um ponto no espaço, obtendo com isso uma noção de proximidade ausente nos demais.

O fundamento é a hipótese distribucional, segundo a qual palavras que ocorrem nos mesmos contextos possuem significados relacionados, e cuja realização em vetores densos treinados por predição de contexto é a de Mikolov *et al.* (2013). O vetor sumariza os contextos de ocorrência da palavra no corpus de treino, e o resultado é uma tabela $\mathbf{v} : \mathcal{V} \rightarrow \mathbb{R}^d$ com uma linha por palavra — aqui a do modelo `pt_core_news_md`, com $d = 300$ e 20.000 linhas. Trata-se de consulta, e não de cálculo, uma vez que o vetor de cada palavra é invariante e está armazenado no modelo. Desta propriedade decorrem tanto os acertos quanto os limites do método: o vetor não codifica o significado da palavra, mas os contextos em que ela habitualmente ocorre.

A comparação é feita pelo cosseno, isto é, pelo ângulo entre os dois vetores:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \quad (26)$$

O valor situa-se entre -1 e $+1$, assumindo 1 quando os vetores apontam na mesma direção e 0 quando são ortogonais. Emprega-se o cosseno, e não a distância euclidiana, porque a norma $\|\mathbf{v}\|$ veicula sobretudo frequência, dado que palavras comuns tendem a vetores de maior comprimento; a divisão pelas duas normas descarta essa magnitude e retém apenas a direção, onde reside a informação contextual.

A extensão mais simples da medida para a frase é a média dos vetores de suas palavras:

$$\mathbf{v}(s) = \frac{1}{|s|} \sum_{t \in s} \mathbf{v}(t) \quad (27)$$

O somatório percorre um multiconjunto, de modo que qualquer reordenação da frase apresenta exatamente os mesmos termos e, por consequência, o mesmo vetor. A invariância à ordem é propriedade da Equação 27, e não contingência de um exemplo. O método devolve um número entre -1 e $+1$ por par comparado.

4 Resultados

Os resultados foram agrupados por técnicas de mesma dimensão, o que permite observar de forma mais clara e focada o que cada uma devolve sob o objetivo comum à dimensão.

4.1 Ortografia

4.1.1 Léxico com distância de edição

O método foi aplicado a três frases do corpus, e a Tabela 2 reúne o que devolveu sobre cada uma.

Frase	Estado	Achado	Correção
Há três dias ... mata natvia	desvio de grafia	natvia	nativa
Há três dias ... mata nativa	correta	—	—
A três dias ... mata nativa	escolha lexical	nenhum	—

Tabela 2: Achados do léxico sobre três frases.

A Equação 1 foi avaliada uma vez por palavra. Sobre a primeira frase, onze avaliações e um único resultado positivo, em **natvia**; sobre a segunda, nenhuma das onze palavras ficou fora de D , e o método não produziu falso positivo.

A correção foi executada apenas para a forma detectada. O algoritmo não busca formas semelhantes: enumera as 949 sequências situadas a uma edição de **natvia** — **aatvia**, **batvia**, **natvi**, **natviaa** e assim por diante — e submete cada uma ao teste de pertinência a D , que elimina 945 delas. Restam as quatro da Tabela 3. Como $C_1(\mathbf{natvia}) \neq \emptyset$, a Equação 2 não escalonou, e as 417.548 sequências situadas a duas edições jamais foram consultadas.

c	Operação sobre natvia	$f(c)$
nativa	transposição de v e i	912
naevia	substituição de t por e	103
natia	remoção do v	77
latvia	substituição de n por l	23

Tabela 3: O conjunto $C(\mathbf{natvia})$, com a frequência de cada candidato no léxico.

Os quatro candidatos equidistam da forma detectada, de modo que a decisão recai integralmente sobre f : a frequência não opera como critério auxiliar de desempate, mas como único critério. A Equação 3 devolveu **nativa**, com 912 ocorrências.

O efeito da métrica adotada se lê na primeira linha da tabela. É a transposição que situa **nativa** a uma edição de **natvia**; sob distância que não a contemple, a permuta custaria 2, a forma correta ficaria fora de C_1 e o $\arg \max$ devolveria **naevia**, o segundo colocado.

A terceira frase contém desvio que o método não alcançou. Em *A três dias* a forma devida é **há**, mas **a** é palavra do português, pertence a D , e a Equação 1 se esgota nesse fato.

O caso delimita o alcance do método e remete a uma distinção que ele não pode fazer: a do erro de grafia, em que a forma não existe, e a do erro de escolha, em que a forma existe mas não é a adequada ao contexto. A detecção avalia uma palavra por vez, isoladamente, e **a**, tomada isoladamente, não apresenta desvio algum. Não se trata de defeito de implementação, mas do comportamento previsto pela fórmula, em que D constitui a definição operacional de erro — e nenhum critério que examine a palavra fora de contexto alcançaria esse caso.

4.2 Gramática

4.2.1 Traços morfossintáticos

O método foi aplicado à variante com desvio de concordância nominal:

Há três dias o incêndio atingiu uma áreas de mata nativa.

A primeira etapa consiste em a Equação 5 determinar quais arcos são admitidos. Dos dez arcos da frase, apenas quatro são examinados, conforme a Tabela 4.

Arco (t, r, h)	r	$h(t)$ é	$T(r)$
(Há, case, dias)	case	—	$\emptyset$
(três, nummod, dias)	nummod	—	$\emptyset$
(dias, obl, atingiu)	obl	—	$\emptyset$
(o, det, incêndio)	det	NOUN	{Number, Gender}
(incêndio, nsubj, atingiu)	nsubj	VERB	{Number, Person}
(uma, det, áreas)	det	NOUN	{Number, Gender}
(áreas, obj, atingiu)	obj	—	$\emptyset$
(de, case, mata)	case	—	$\emptyset$
(mata, nmod, áreas)	nmod	—	$\emptyset$
(nativa, amod, mata)	amod	NOUN	{Number, Gender}

Tabela 4: Os dez arcos da frase e o conjunto de traços que cada um exige.

Seis arcos recaem no terceiro caso da expressão. O de **mata** corresponde precisamente ao caso antecipado na subseção 3.2: substantivo ligado a substantivo por **nmod** **não** estabelece concordância, e sua inclusão faria o método acusar toda frase dotada de complemento nominal.

Em seguida, cada arco admitido desdobra-se nos traços especificados por $T(r)$, conforme a Tabela 5.

Arco	τ	$\hat{\mu}_\tau(t)$	$\hat{\mu}_\tau(h)$	Veredito
(o, det, incêndio)	Number	Sing	Sing	iguais
	Gender	Masc	Masc	iguais
(incêndio, nsubj, atingiu)	Number	Sing	Sing	iguais
	Person	$\perp$	3	comparação suprimida
(uma, det, áreas)	Number	Sing	Plur	$\in E(s)$
	Gender	Fem	Fem	iguais
(nativa, amod, mata)	Number	Sing	Sing	iguais
	Gender	Fem	Fem	iguais

Tabela 5: As comparações efetuadas sobre os quatro arcos admitidos.

Donde

$$E(s) = \{ (\text{uma}, \text{áreas}, \text{Number}) \} \quad (28)$$

A quarta linha exemplifica a guarda $\hat{\mu}_\tau(\cdot) \neq \perp$. O substantivo **incêndio** não porta traço de pessoa, ao passo que o verbo apresenta **Person** = 3. A comparação é suprimida: o resultado não

é de igualdade, mas de ausência de termos a comparar. Sem essa guarda, todo sujeito nominal do português seria computado como discordante de seu verbo quanto à pessoa.

A saída, por sua vez, não é um escore. A tripla (*uma*, *áreas*, *Number*) identifica a palavra responsável, o termo com o qual ela diverge e o traço violado; a esses se soma o arco **det** que os liga — quatro informações passíveis de apresentação ao autor do texto.

4.2.2 Regras escritas à mão

O método foi aplicado a duas variantes. Disparou sobre a primeira e não disparou sobre a segunda.

Sobre *A três dias o incêndio atingiu uma área de mata nativa*, a Equação 9 devolveu um único par, na posição inicial:

$$D(s) = \{ (0, \text{CONFUSÃO_À_HÁ}) \} \quad (29)$$

A Tabela 6 apresenta os campos que acompanham o disparo.

Campo	Valor	Conteúdo
ruleId	CONFUSÃO_À_HÁ	a regra que casou — o r da fórmula
offset	0	a posição do casamento — o i da fórmula
errorLength	1	a extensão do casamento
trecho	'A'	o segmento coberto por π_r
replacements	['Há']	a correção que a regra carrega
message	"... substitua por há."	a norma, redigida em português

Tabela 6: Campos de um disparo do LanguageTool.

O par (i, r) constitui a localização. A última linha corresponde ao que nenhum outro método fornece: um enunciado em português que explicita a norma, redigido conjuntamente com o padrão. Trata-se, ademais, precisamente do caso que o léxico não alcança — **a** pertence a D , conforme a subseção 4.1.1, e apenas uma regra de elaboração manual detecta a troca.

Sobre *Há três dias os incêndios atingiu uma área de mata nativa*, em que o sujeito no plural se combina com verbo no singular, nenhuma das 2.270 regras casou, donde $D(s) = \emptyset$. É a Equação 10 verificada em um caso concreto: existe regra de concordância verbal em R , mas nenhum de seus padrões cobre esta construção, e o desvio não é detectado. Não há grau de confiança a inspecionar nem resultado parcial a interpretar — a saída é a mesma de uma frase correta.

O contraste entre as duas frases delimita o método. A troca *a/há* é detectada porque alguém escreveu π_r para ela; a discordância entre **os incêndios** e **atingiu** não é detectada porque ninguém escreveu. Nenhuma das duas decisões é propriedade da língua, e ambas são propriedade de R .

4.2.3 SLOR

O método foi aplicado à frase de referência e à sua permutação, par que isola a ordem: as duas apresentam exatamente as mesmas onze palavras e diferem apenas na sequência em que aparecem.

Por isso o termo $\ln P_{\text{uni}}$ da Equação 12 é idêntico nas duas, valendo $-81,95$ — a distribuição unigrama percorre um multiconjunto e ignora a ordem. Toda a diferença reside no primeiro termo, que é precisamente a grandeza que a Equação 11 foi construída para isolar. A Tabela 7 abre o somatório posição a posição.

Token	$\ln P(w_i w_{i-1})$	$\ln P(w_i)$	contrib.	$c(w_{i-1}, w_i)$
<i>Há três dias o incêndio atingiu uma área de mata nativa</i>				
há	-5,54	-6,72	+1,18	259
três	-3,92	-7,10	+3,18	36
dias	-3,73	-7,39	+3,67	30
o	-3,23	-2,86	-0,37	21
incêndio	-8,25	-10,41	+2,16	22
atingiu	-11,47	-10,27	-1,20	0
uma	-6,19	-4,98	-1,20	0
área	-6,37	-8,16	+1,79	17
de	-1,09	-2,49	+1,40	135
mata	-10,00	-9,99	-0,01	4
nativa	-3,53	-11,58	+8,04	2
SLOR = $(-63,32 - (-81,95)) / 11$				+1,694
<i>nativa uma incêndio há mata de o área três atingiu dias</i>				
nativa	-12,78	-11,58	-1,20	0
uma	-6,19	-4,98	-1,20	0
incêndio	-11,62	-10,41	-1,20	0
há	-7,93	-6,72	-1,20	0
mata	-11,19	-9,99	-1,20	0
de	-3,69	-2,49	-1,20	0
o	-1,94	-2,86	+0,92	16.033
área	-9,24	-8,16	-1,08	1
três	-8,30	-7,10	-1,20	0
atingiu	-11,47	-10,27	-1,20	0
dias	-8,60	-7,39	-1,20	0
SLOR = $(-92,94 - (-81,95)) / 11$				-1,000

Tabela 7: As parcelas do numerador, posição a posição, sobre o par de ordem. A coluna *contrib.* é $\ln P(w_i | w_{i-1}) - \ln P(w_i)$; em negrito, os bigramas não observados, cuja contribuição vale $\ln(1 - \lambda) = -1,204$.

O sinal se comporta conforme a definição prevê: positivo na frase bem ordenada, +1,694, e negativo na embaralhada, -1,000. Aberto o somatório, contudo, o que sustenta cada um dos dois valores se revela mais estreito do que o par sugere.

Na frase embaralhada, nove das onze parcelas correspondem a bigramas não observados e valem -1,204, conforme a Equação 14. O escore não mede anti-estrutura, mas a quase ausência de evidência: é o piso, levemente levantado por uma única contribuição positiva, a de **o** precedido de **de**, par observado 16.033 vezes. Trata-se de adjacência entre preposição e artigo que sobreviveu ao embaralhamento por acidente, e não de vestígio de estrutura preservada.

A frase correta apoia-se em base igualmente estreita. Duas de suas onze posições — **atingiu** e **uma** — já estão no piso, ainda que a frase esteja bem construída. E a parcela de **nativa** responde sozinha por 8,04 dos 18,63 do numerador, isto é, por 43% do resultado; ela provém do bigrama **mata nativa**, observado **duas** vezes em um milhão de tokens.

O método separa o par, portanto, e o faz na direção correta. Mas a separação repousa, de um lado, sobre uma coocorrência vista duas vezes e, de outro, sobre a ausência de quase toda coocorrência — e não sobre uma medida de ordem que seja robusta ao corpus de contagens.

4.2.4 PLL

O método foi aplicado a quatro frases: a de referência e três variantes, cada uma com desvio de natureza distinta. Todas apresentam $|s| = 12$, de modo que soma e média ordenam do mesmo

modo. A Tabela 8 apresenta os dois valores.

Frase	Estado	Soma	PLL
Há três dias o incêndio atingiu uma área...	correta	-9,16	-0,763
Há três dias os incêndios atingiu uma área...	conc. verbal	-15,16	-1,263
Há três dias o incêndio cantou uma área...	seleção verbal	-26,30	-2,192
nativa uma incêndio há mata de o área...	embaralhada	-124,97	-10,414

Tabela 8: O PLL sobre a frase de referência e três variantes.

A ordenação acompanha a gravidade do desvio, e as distâncias entre os degraus são amplas: a frase correta separa-se da variante de concordância por meio nat por posição, esta da anomalia de seleção por quase um nat, e a embaralhada situa-se uma ordem de grandeza abaixo de todas. Diferentemente do SLOR, nenhum dos quatro valores decorre de piso do estimador — não há suavização nem recuo, apenas a distribuição que o modelo atribui a cada posição.

A localização do desvio, contudo, só aparece antes da agregação. A Tabela 9 abre a Equação 15 posição a posição sobre o par mínimo de concordância verbal.

Frase correta		Com desvio		Δ
Token	$\ln P_{\text{MLM}}$	Token	$\ln P_{\text{MLM}}$	
Há	-0,43	Há	-1,41	-0,98
três	-2,05	três	-2,33	-0,28
dias	-0,59	dias	-0,90	-0,31
o	-2,14	os	-1,47	+0,67
incêndio	-1,95	incêndios	-1,65	+0,30
atingiu	-0,91	atingiu	-6,09	-5,18
uma	-0,06	uma	-0,22	-0,16
área	-0,07	área	-0,09	-0,02
de	-0,04	de	-0,04	0,00
mata	-0,21	mata	-0,26	-0,05
nativa	-0,70	nativa	-0,69	+0,01
.	-0,00	.	-0,00	0,00
soma	-9,16	soma	-15,16	-6,00

Tabela 9: As parcelas da Equação 15 sobre o par mínimo de concordância verbal.

Dos 6,00 nats de diferença entre as duas somas, 5,18 concentram-se em uma única posição, a do verbo: *atingiu* passa de -0,91 para -6,09. Manifesta-se aqui a bidirecionalidade do modelo, uma vez que, ao mascarar o verbo, ele dispõe de *os incêndios* à esquerda e conclui pela inadequação do singular. O método, portanto, não apenas ordena as duas frases: indica onde elas diferem.

Convém observar de que natureza é essa indicação. O desvio é uma discordância *entre* sujeito e verbo, e nada na frase determina qual dos dois está errado — *os incêndios atingiram* e *o incêndio atingiu* são ambas corretas. O modelo, no entanto, atribui a totalidade da penalidade ao verbo: mascaradas, as formas *os* e *incêndios* tornam-se *mais* prováveis do que suas contrapartes no singular, com Δ positivo. A localização produzida é uma atribuição do modelo, e não um fato linguístico sobre a frase.

4.3 Estrutura

4.3.1 Teste do núcleo predicativo

O método foi aplicado a quatro frases: a de referência, o fragmento, uma predicação nominal e um infinitivo isolado. Das quatro, acertou três e errou uma. A Tabela 10 confronta o veredito da

Equação 18 com o esperado.

Frase	Raiz	Veredito	Esperado	
Há três dias... atingiu...	atingiu (VERB, Fin)	ORAÇÃO	ORAÇÃO	ok
Há três dias... que atingiu...	dias (NOUN)	FRAGMENTO	FRAGMENTO	ok
O incêndio é intenso.	intenso (ADJ + cop)	ORAÇÃO	ORAÇÃO	ok
Atingir uma área...	Atingir (VERB, Inf)	ORAÇÃO	FRAGMENTO	erro

Tabela 10: O teste da raiz sobre quatro frases, com o veredito confrontado ao esperado.

O acerto se dá pelos dois modos de a Equação 18 ser satisfeita, e cada frase correta exercita um. Na de referência a raiz é **atingiu**, com pos = VERB, e o primeiro termo da disjunção basta. Em *O incêndio é intenso* a raiz é o adjetivo **intenso**, o primeiro termo é falso, e a aprovação vem do segundo, que encontra **é** entre os dependentes com função **cop**.

A frase sem predicado é a segunda. O pronome **que** rebaixa **atingiu** a **acl:relcl**, a raiz passa a **dias**, que é NOUN e não tem dependente copular, e os dois termos da disjunção são falsos. Uma única palavra inverte o veredito, e nenhum outro método examinado registra a diferença, uma vez que as duas frases contêm o mesmo verbo. Registre-se que nessa frase o analisador devolveu dois nós ROOT, **dias** e **incêndio**; a implementação retém o primeiro, e por serem ambos NOUN o veredito não depende da escolha.

O erro é a quarta. Em *Atingir uma área de mata nativa em três dias* a raiz é **Atingir**, também VERB, de modo que o primeiro termo da disjunção é satisfeito exatamente como na frase de referência. Trata-se, porém, de infinitivo isolado, que não constitui predicação. A informação que separaria os dois casos está na árvore, na forma do traço **VerbForm = Inf**, e a Equação 18 não a consulta.

4.3.2 Comprimento de dependência e não-projetividade

As duas medidas foram aplicadas a um par de frases auxiliares que compartilha as mesmas 13 palavras, os mesmos 12 arcos e as mesmas duas orações relativas, diferindo apenas na posição em que estas foram encaixadas. Ambas são corretas. A Tabela 11 abre a Equação 19 arco a arco.

t	$h(t)$	$d(t)$	rótulo
<i>O vento agravou a seca que intensificou o fogo que destruiu a mata.</i>			
0	vento	1	det
vento	agravou	1	nsubj
a	seca	1	det
seca	agravou	2	obj
que	intensificou	1	nsubj
intensificou	seca	2	acl:relcl
o	fogo	1	det
fogo	intensificou	2	obj
que	destruiu	1	nsubj
destruiu	fogo	2	acl:relcl
a	mata	1	det
mata	destruiu	2	obj
$ A = 12$	$D = 17$	$\bar{D} = 1,42$	maior arco 2 $X = 0$
<i>O fogo que a seca que o vento agravou intensificou destruiu a mata.</i>			
0	fogo	1	det
fogo	destruiu	9	nsubj
que	intensificou	7	obj
a	seca	1	det
seca	intensificou	5	nsubj
que	agravou	3	obj
o	vento	1	det
vento	agravou	1	nsubj
agravou	seca	4	acl:relcl
intensificou	fogo	8	acl:relcl
a	mata	1	det
mata	destruiu	2	obj
$ A = 12$	$D = 43$	$\bar{D} = 3,58$	maior arco 9 $X = 0$

Tabela 11: Os doze arcos de cada frase, com seu comprimento, e as duas medidas resultantes.

O comprimento de dependência separa as duas frases com margem ampla. Na primeira nenhum arco excede 2: cada relativa se vincula ao substantivo imediatamente anterior, e a frase se resolve da esquerda para a direita sem retenção. Na segunda os vínculos se acumulam — **fogo** encontra seu verbo nove posições adiante, e **intensificou** o seu, oito — e $\bar{D}$ mais que duplica. Como referência aproximada, a prosa corrente situa-se entre 1 e 2 nas línguas para as quais a medida foi levantada em larga escala (Futrell; Mahowald; Gibson, 2015); acima de 3, a frase mantém número elevado de vínculos simultaneamente em aberto.

A não-projetividade não separa nada. X é nulo nas duas frases, inclusive na segunda, cujo encaixamento é central. Decorre das desigualdades estritas da Equação 20: arcos que compartilham extremidade não contam como cruzados, e o encaixe de uma relativa no interior de outra produz arcos aninhados, não sobrepostos. A medida é definida e correta, e sobre este corpus não devolve informação alguma.

Vale o mesmo registro da subseção anterior: as duas frases são corretas, de modo que nenhuma das medidas emite veredito. O que $\bar{D}$ separa é a carga de processamento imposta pela ordem escolhida, não a boa formação.

4.4 Semântica

4.4.1 Surpresa por token

O método foi aplicado a três frases: a de referência, sua variante com anomalia de seleção verbal e uma frase correta de vocabulário do domínio. Das três, o $\arg \max$ da Equação 24 apontou a palavra devida em uma. A Tabela 12 confronta o pico com a palavra que de fato apresenta desvio.

Frase	Estado	Pico	Palavra com desvio	
Há três dias... atingiu...	correta	atingiu (11,47)	nenhuma	erro
Há três dias... cantou...	seleção verbal	cantou (13,70)	cantou	ok
Focos recorrentes...	correta	anômala (15,08)	nenhuma	erro

Tabela 12: O pico de surpresa, em nats, confrontado com a palavra que apresenta desvio.

A Tabela 13 abre o perfil das duas primeiras frases, que diferem em uma única palavra.

Frase correta			Com anomalia		
Token	surp	$c(bi)$	Token	surp	$c(bi)$
há	5,54	259	há	5,54	259
três	3,92	36	três	3,92	36
dias	3,73	30	dias	3,73	30
o	3,23	21	o	3,23	21
incêndio	8,25	22	incêndio	8,25	22
atingiu	11,47	0	cantou	13,70	0
uma	6,19	0	uma	6,19	0
área	6,37	17	área	6,37	17
de	1,09	135	de	1,09	135
mata	10,00	4	mata	10,00	4
nativa	3,53	2	nativa	3,53	2

Tabela 13: Perfis de surpresa das duas frases, em nats. Em negrito, a posição que difere e as de bigrama não observado.

Onde o contexto intervém, a medida faz o que promete. Isoladamente, **nativa** é palavra de frequência muito baixa, com surpresa de 11,58; precedida de **mata**, é praticamente esperada e o valor cai para 3,53. É o comportamento pretendido: mensurar a palavra em posição, e não em abstrato.

O acerto da segunda linha da Tabela 12 é igualmente legítimo. Trocado **atingiu** por **cantou**, apenas aquela posição se altera — as outras dez permanecem idênticas até a segunda casa —, e o pico acompanha a troca. O método é local, e o perfil registra a mudança onde ela ocorreu.

Os dois erros, contudo, têm a mesma origem, e ela está na Equação 23. Os três picos recaem sobre posições de bigrama não observado, onde a surpresa vale $\text{surp}_{\text{uni}} + 1,204$: $11,47 = 10,27 + 1,20$, $13,70 = 12,49 + 1,20$ e $15,08 = 13,88 + 1,20$. Nenhum deles mede contexto. Na frase de referência, que não tem desvio algum, o pico recai sobre **atingiu** porque **incêndio atingiu** não foi observado no corpus de contagens — e o $\arg \max$ aponta a palavra correta de uma frase correta. Em *Focos recorrentes apresentaram persistência anômala* o caso é extremo: os cinco bigramas são não observados, todo o perfil é unigrama deslocado de 1,204, e o pico é simplesmente a palavra mais rara, no valor de teto do estimador.

A suposição registrada na subseção 3.8 — a de que *improvável* e *incorreto* coincidam — é, portanto, o que o método efetivamente mede. O $\arg \max$ seleciona a palavra mais rara, e isso coincide com o desvio apenas quando o desvio é uma palavra rara. Foi o que ocorreu com **cantou**, e é contingência do exemplo, não propriedade do método.

4.4.2 Plausibilidade do verbo mascarado

O método foi aplicado a cinco frases: três em que a raiz é verbo e duas em que não é. A Tabela 14 apresenta as duas leituras da Equação 25.

Frase	Estado	$\ln P(v_\rho)$	$m(s)$	
... o incêndio destruiu uma área...	paráfrase	-0,72	0,00	ok
... o incêndio atingiu uma área...	referência	-0,91	0,20	ok
... o incêndio cantou uma área...	seleção verbal	-14,45	13,73	ok
... o incêndio que atingiu...	fragmento	n/a — raiz dias (NOUN)	—	—
O incêndio é intenso.	predic. nominal	n/a — raiz intenso (ADJ)	—	—

Tabela 14: A margem do verbo da raiz. As formas esperadas são as mesmas nas três primeiras frases: [destruiu, atingiu, atinge, invadiu, em].

A separação é ampla: quase 14 nats entre o verbo anômalo e os dois adequados, que se situam junto ao zero. A primeira linha fixa o significado desse zero — **destruiu** é a primeira escolha do modelo, e por isso a margem é exatamente nula. A escala não é arbitrária.

O aspecto metodologicamente relevante é a lista de formas esperadas ser idêntica nas três frases, e não poderia ser diferente: ao mascarar a raiz, suprime-se justamente a única palavra em que as três diferem, de modo que o contexto remanescente é o mesmo. O instrumento de medida permanece fixo e apenas o objeto mensurado varia, e é essa condição que torna a comparação legítima. Nenhum dos métodos anteriores dispõe dela: no SLOR e na surpresa, mudar a palavra muda também as contagens que servem de referência.

As duas últimas linhas exercitam a cláusula de não aplicabilidade. No fragmento a raiz é **dias**, e na predicação nominal é **intenso**: em nenhum dos dois casos há verbo na raiz para mascarar, e a resposta é **n/a**. Não se trata de falha, e sim do comportamento previsto na subseção 3.9 — reconhecer a não aplicabilidade integra o emprego correto do método. Note-se, contudo, que essa cláusula transfere a decisão para o analisador sintático: as duas frases receberam **n/a** porque a árvore predita as classificou assim, e a subseção 4.3.1 mostrou que essa árvore nem sempre é única nem completa.

Resta a folga apontada na definição. A quinta posição da lista esperada é **em**, uma preposição, o que confirma que $\mathcal{V}$ não está restrito a formas verbais. Neste corpus a folga é inconsequente, pois $\hat{v}$ foi **destruiu** nas três frases; mas nada na Equação 25 impede que o melhor preenchimento seja uma palavra de outra classe, caso em que a margem passaria a medir a distância até ela.

4.4.3 Embeddings

A Equação 26 foi aplicada a onze pares de palavras do domínio, agrupados em sinônimos, antônimos e pares sem relação. A Tabela 15 os apresenta ordenados por proximidade.

Par	Relação	cos
seco × úmido	antônimos	+0,838
quente × frio	antônimos	+0,690
área × região	sinônimos	+0,658
chamas × fogo	sinônimos	+0,648
mata × floresta	sinônimos	+0,610
início × fim	antônimos	+0,562
incêndio × fogo	sinônimos	+0,509
ativo × extinto	antônimos	+0,263
fogo × sintaxe	sem relação	+0,065
incêndio × gramática	sem relação	+0,005
área × advérbio	sem relação	−0,063

Tabela 15: Cossenos entre pares de palavras do domínio, ordenados por proximidade.

O bloco inferior estabelece a referência de leitura: os três pares sem relação situam-se junto a zero, entre $-0,063$ e $+0,065$, de modo que o zero corresponde de fato à ausência de relação e é contra ele que os demais valores devem ser interpretados. Nesse aspecto a medida se comporta como esperado.

O bloco superior não separa o que se pretenderia separar. O par de maior proximidade em toda a tabela é um par de *opostos*: **seco × úmido**, com $+0,838$, supera todos os sinônimos, inclusive **incêndio × fogo** ($+0,509$), cujos termos designam praticamente a mesma entidade. Antônimos e sinônimos aparecem intercalados ao longo de toda a coluna, e nenhum ponto de corte os separa.

Não se trata de defeito do modelo, mas do funcionamento previsto da hipótese distribucional. **Seco** e **úmido** ocorrem exatamente nos mesmos contextos — *clima* __, *solo* __, *período* __ — e, como o vetor sumariza contextos, ambos recebem direções quase coincidentes. Já **incêndio** e **fogo** pertencem a registros distintos, o primeiro designando o evento noticiado e o segundo o elemento. O cosseno mensura campo temático, e não sentido, e a informação que separaria equivalência de oposição nunca foi incorporada ao vetor (Faruqui *et al.*, 2016; Schnabel *et al.*, 2015).

A extensão à frase foi verificada sobre um par de permutação. Aplicada a Equação 27 a *O fogo atingiu o vale* e *O vale atingiu o fogo*, o cosseno entre os dois vetores resultantes é 1,000000: as duas frases são, para o método, indistinguíveis. É a confirmação numérica da invariância derivada na subseção 3.10, e ela exclui a medida de qualquer verificação que dependa de ordem — o que inclui a permutação do corpus, detectada pelo SLOR e pelo PLL.

Um último registro delimita o alcance. Consultada a tabela para **natvia**, a forma não possui vetor, e o modelo devolve o vetor nulo, de norma 0,00. Sobre uma palavra fora da tabela o método não produz medida errada: não produz medida alguma. É exatamente o caso que a subseção 4.1.1 mostrou ser o único que o léxico decide com exatidão.

5 Discussão

5.1 Ortografia

A dimensão dispõe de um único método, e é ele que devolve o veredito mais forte de todo o levantamento. A pertinência a D não é estimada nem aproximada: a palavra consta ou não consta do conjunto, sem gradação e sem margem. É também o único método que, além do diagnóstico, devolve a correção — sobre **natvia**, a Equação 3 apontou **nativa** sem ambiguidade, e a subseção 4.1.1 não registrou falso positivo sobre a frase correta.

Dois problemas delimitam o que a dimensão alcança, e eles são de naturezas distintas.

O primeiro é de fronteira, e é intrínseco à definição. Em *A três dias* o método não produziu

achado, porque **a** é palavra do português e pertence a D . A Equação 1 avalia uma palavra por vez, isoladamente, e **a**, tomada isoladamente, não apresenta desvio algum.

O segundo problema é de procedência, e afeta o que o método devolve quando acerta. O léxico é uma lista de frequências, e não um dicionário: o conjunto de candidatos herda o que o corpus de origem contém. Dos quatro candidatos a uma edição de **natvia** na Tabela 3, apenas **nativa** é palavra corrente do português; **naevia** e **natia** não constam de dicionário normativo, e **latvia** é forma estrangeira. São candidatos por terem sido atestados no material de origem, e não por serem palavras do idioma. O desempate segue a mesma lógica, uma vez que a decisão recai integralmente sobre f : **nativa** vence com 912 ocorrências, então, a qualidade do resultado esta diretamente ligada ao corpus utilizado.

5.2 Gramática

A dimensão reúne quatro métodos, e eles se dividem em dois grupos pelo tipo de resposta. Os traços morfossintáticos e as regras escritas à mão devolvem um veredito localizado; o SLOR e o PLL devolvem um número.

Os dois primeiros acertam onde têm cobertura, sendo assim, dependem das regras bem descritas. As regras detectaram a troca em *A três dias* e são o único método do levantamento a devolver, junto com o achado, o enunciado da norma em português; mas sobre *os incêndios atingiu* nenhuma das 2.270 regras casou, e $D(s) = \emptyset$ é indistinguível da saída de uma frase correta. É a Equação 10 verificada em caso concreto: a cobertura de R é finita e de elaboração manual, e o português dispõe de 249 grupos de regras. Os traços, por sua vez, localizaram o desvio de *uma áreas* com precisão que nenhum outro método alcança — a palavra, o termo com que diverge, o traço violado e o arco que os liga —, mas deixaram passar *a área inteiro*: o adjetivo posposto está no masculino e ainda assim $E(s) = \emptyset$, porque o anotador atribuiu **Gender** = Fem a *inteiro* e a comparação devolveu *iguais*. A fórmula está correta e o insumo não está, e é por isso que a Equação 6 compara $\hat{\mu}()$, e não $\mu()$.

Os dois métodos de escore ordenam, mas não decidem. O PLL ordenou as quatro frases na direção certa, com degraus amplos, e ainda localizou o desvio, uma vez que 5,18 dos 6,00 nats de diferença se concentram na posição do verbo. Essa localização, porém, é atribuição do modelo e não fato da frase: a discordância é *entre* sujeito e verbo, e mascaradas as formas **os** e **incêndios** tornam-se mais prováveis que suas contrapartes no singular. Nenhum dos dois métodos dispõe de limiar, de modo que os valores são interpretáveis entre si e nenhum isoladamente.

No SLOR soma-se um problema do estimador. O par de ordem foi separado na direção prevista, mas a Tabela 7 mostra sobre o que a separação repousa: nove das onze parcelas da frase embaralhada estão no piso $\ln(1 - \lambda) = -1,204$, e a única contribuição positiva vem de **de** o, adjacência entre preposição e artigo que sobreviveu ao embaralhamento por acidente; do outro lado, 43% do numerador da frase correta provém de um único bigrama observado duas vezes. O escore não distingue frase mal construída de frase cujo vocabulário o corpus de contagens não cobre, e assim nenhum dos quatro métodos decide sozinho sobre concordância, dois são dependentes de regras que podem falhar em casos de cenários fora de sua cobertura e dois não dispõem de limiar.

5.3 Estrutura

Os dois métodos da dimensão ocupam posições opostas quanto ao que se pode extrair deles. O teste da raiz devolve veredito binário e localizado ao custo de inspecionar um único nó; o comprimento de dependência e a não-projetividade devolvem descritores que não respondem à pergunta da correção.

O teste da raiz registra uma distinção que nenhum outro método do levantamento alcança. Entre *o incêndio atingiu* e *o incêndio que atingiu* não há diferença de vocabulário — o mesmo verbo está presente nas duas —, e o que separa oração de fragmento é a posição que ele ocupa

na árvore. Das quatro frases a que foi submetido, o método acertou três, aprovando a frase de referência pelo primeiro termo da disjunção e a predicação nominal pelo segundo, e reprovando o fragmento por ambos serem falsos.

O erro é de espécie mais simples que os da dimensão anterior. Em *Atingir uma área de mata nativa em três dias* a raiz é **Atingir**, também VERB, e o infinitivo isolado é aprovado como oração. O traço que separaria os dois casos — **VerbForm = Inf** — está na árvore, corretamente atribuído, e a Equação 18 simplesmente não o consulta. Diferentemente do que ocorreu com os traços morfossintáticos, aqui o insumo está correto e a falha é da definição, portanto corrigível dentro dela.

Uma ressalva recai sobre a árvore que o método lê. A notação $\rho(s)$ pressupõe unicidade, e o analisador não a garante: sobre o fragmento devolveu uma floresta, com **dias** e **incêndio** ambos etiquetados ROOT. A implementação retém o primeiro, e no caso o veredito não depende da escolha, pois os dois candidatos são NOUN — mas o acerto se deu sobre uma entrada que a definição não previa.

O segundo método não emite veredito algum, e o corpus deixa isso explícito: as duas frases a que foi aplicado são corretas e diferem apenas na posição em que as relativas foram encaixadas. O comprimento médio as separa com margem ampla, de 1,42 para 3,58, com o maior arco passando de 2 para 9, o que mensura a carga de processamento imposta pela ordem escolhida. Já a não-projetividade devolveu $X = 0$ nas duas: as desigualdades da Equação 20 são estritas, e o encaixe de uma relativa no interior de outra produz arcos aninhados, não sobrepostos. A medida está correta e sobre este corpus não informa nada, de modo que da dimensão inteira apenas o teste da raiz é aproveitável para decidir sobre uma frase.

5.4 Semântica

A dimensão reúne três métodos, e apenas um deles produziu decisão utilizável.

O verbo mascarado separou o verbo anômalo dos adequados por quase 14 nats, e o zero de sua escala tem significado, uma vez que **destruiu** é a primeira escolha do modelo e recebe margem exatamente nula. Mais relevante que a separação, porém, é a condição que a torna legítima: a lista de formas esperadas é idêntica nas três frases, porque mascarar a raiz suprime justamente a única palavra em que elas diferem. O instrumento de medida permanece fixo enquanto o objeto varia — propriedade que nenhum outro método do levantamento possui, dado que no SLOR e na surpresa trocar a palavra altera também as contagens que servem de referência.

Duas ressalvas acompanham o método. A resposta **n/a** sobre o fragmento e a predicação nominal é comportamento previsto, e não falha, mas transfere a decisão ao analisador sintático: as duas frases foram recusadas porque a árvore predita as classificou assim. E $\mathcal{V}$ não está restrito a formas verbais, como mostra a preposição **em** entre as cinco esperadas; neste corpus a folga é inconsequente, pois $\hat{v}$ foi **destruiu** nas três frases, mas nada na Equação 25 impede que o melhor preenchimento seja palavra de outra classe.

A surpresa por token acertou uma das três frases e errou duas, e os três picos têm a mesma origem. Todos recaem sobre posições de bigrama não observado, onde vale $\text{surp}_{\text{uni}} + 1,204$: na frase de referência, que não contém desvio, o pico caiu sobre **atingiu** apenas porque **incêndio atingiu** não consta do corpus de contagens. Em *Focos recorrentes apresentaram persistência anômala* o caso é extremo, pois os cinco bigramas são não observados, todo o perfil é unigrama deslocado de uma constante, e o pico é a palavra mais rara no valor de teto do estimador. O $\arg \max$ seleciona raridade, e o acerto sobre **cantou** é contingência de o desvio ser também uma palavra rara.

Os embeddings falham por motivo distinto. O bloco de pares sem relação comporta-se como esperado, situando-se junto a zero, mas o bloco superior não separa o que deveria: o par de maior proximidade de toda a Tabela 15 é um par de opostos, **seco** $\times$ **úmido** com +0,838, acima de todos os sinônimos e do próprio **incêndio** $\times$ **fogo**. Não é defeito do modelo, e sim a hipótese distribucional operando como definida, pois os dois termos ocorrem nos mesmos

contextos. Some-se que a Equação 27 é invariante à ordem — verificada em 1,000000 sobre o par de permutação — e que *natvia*, fora da tabela de vetores, não recebe medida alguma.

Das três, portanto, apenas o verbo mascarado sobrevive à caracterização, e as duas exclusões se dão por razões opostas: a surpresa mede raridade em lugar de desvio, e o cosseno mede campo temático em lugar de sentido.

5.5 A pipeline

Tendo em vista os resultados obtidos, observa-se uma abordagem por partição: cada um alcança um tipo de desvio e falha em outros. Realizando uma análise segmentada, podemos priorizar técnicas em que as falhas não coincidem. — *A três dias* escapa ao léxico e é detectada pelas regras; *os incêndios atingiu* escapa às regras e é detectada pelo PLL. Encadear os métodos é a resposta que decorre dessa observação, e o que se apresenta a seguir é uma sugestão de cadeia, não um resultado do levantamento.

Propõem-se então quatro etapas, uma por dimensão, cada qual ocupada pelo método que a discussão anterior identificou como o único da sua dimensão a produzir veredito localizado sem parâmetro a calibrar:

$$\begin{array}{ccccccc} \text{ortografia} & \rightarrow & \text{estrutura} & \rightarrow & \text{gramática} & \rightarrow & \text{semântica} \\ \text{léxico} & & \text{teste da raiz} & & \text{traços} & & \text{verbo mascarado} \end{array}$$

A primeira etapa é o léxico porque é o único veredito do levantamento que não depende de estimativa: a palavra consta ou não consta de D . É também o único método que devolve a correção junto com o diagnóstico. A ressalva da subseção 5.1 permanece — a qualidade do que ele devolve está ligada ao corpus que originou a lista —, mas ela afeta a correção sugerida, não a detecção.

A segunda é o teste da raiz porque, das duas técnicas estruturais, é a única que emite veredito: o comprimento de dependência mede carga de processamento sobre frases corretas, e a não-projetividade não separou nada. Pesa a favor dele que sua única falha, a aprovação do infinitivo isolado, seja corrigível dentro da própria definição, bastando que a Equação 18 passe a exigir $\text{VerbForm} = \text{Fin}$ na raiz. É a correção que a cadeia pressupõe.

A terceira são os traços morfossintáticos, e não as regras escritas à mão, embora as duas detectem desvios reais. A razão é a forma da cobertura: $T(r)$ é uma condição sobre classes de arcos e vale para toda ocorrência da classe, ao passo que R é um conjunto finito de padrões individuais, cuja ausência de item torna o desvio invisível. Os traços também localizam com a precisão mais fina do levantamento. As regras permanecem, contudo, a extensão mais imediata da cadeia, uma vez que detectam a escolha lexical, que é o desvio que nenhuma das quatro etapas alcança.

A quarta é o verbo mascarado por ser o único método semântico que sobreviveu à caracterização, e porque é o único de todo o levantamento cujo instrumento de medida permanece fixo enquanto o objeto varia.

A ordem das quatro não é escolha de projeto. A ortografia vem primeiro porque uma palavra fora do léxico não permanece contida nessa etapa: ela deforma a árvore de dependências que as três etapas seguintes leem. A estrutura precede a gramática porque a existência de predicado é condição para que os arcos de concordância estejam corretamente atribuídos, e o teste da raiz a verifica a custo desprezível. E a semântica encerra a cadeia porque o verbo mascarado devolve *n/a* quando a raiz não é verbo, de modo que depende da verificação estrutural. Cabe registrar que essa dependência não é estrita: uma predicação nominal passa pela segunda etapa e ainda assim recebe *n/a* na quarta, pois ter predicado e ter verbo na raiz não são a mesma condição.

Aplicada a cadeia, cada etapa devolve um achado ou nada, e a frase é reprovada quando alguma delas produz achado. As quatro são executadas sempre, ainda que a primeira já reprove: a decisão de não bloquear é o que torna o laudo legível, pois expõe todos os desvios de uma vez em lugar de um por passagem. A Tabela 16 apresenta o laudo de duas frases do corpus.

Etapa		Achado
<i>Há três dias o incêndio atingiu uma áreas de mata natvia.</i>		
ortografia	ok	—
estrutura	ok	predicado presente
gramática	!!	Number: uma(Sing) × áreas(Plur) [det]
semântica	ok	atingiu, margem 0,65
<i>Há tres dias o incêndio atingiu uma áreas de mata natvia.</i>		
ortografia	!!	natvia → nativa
estrutura	ok	predicado presente †
gramática	!!	Number: uma(Sing) × áreas(Plur) [det] †
semântica	ok	atingiu, margem 0,95 †

Tabela 16: Laudo da cadeia sobre duas frases. † etapa marcada como *árvore sob suspeita*, por ler uma árvore construída sobre palavra fora do léxico.

A primeira frase contém um único desvio, e a cadeia o localiza na etapa que lhe corresponde. A segunda acrescenta uma palavra fora do léxico, e é ela que expõe o custo do encadeamento: a forma **natvia** não permanece contida na primeira etapa, pois deforma a árvore de dependências que as três seguintes leem. Daí a marcação *árvore sob suspeita*, que não indica incorreção, mas confiabilidade menor — e que é a resposta prática ao limite enunciado na subseção 5.2, o de que uma cadeia de etapas que leiam a mesma árvore predita herda os erros dessa predição.

No caso examinado a deformação não atingiu o arco relevante, e o achado de concordância permanece legítimo nas duas frases. Trata-se, contudo, de contingência posicional, e não de garantia: a marcação existe justamente porque a cadeia não tem como distinguir os dois casos.

Cabe observar, por fim, que a quarta etapa não produz achado em nenhuma das duas frases, com margens de 0,65 e 0,95. O ganho dela não se manifesta neste par, cujos desvios são de ortografia e de concordância; ela se destina à anomalia de seleção verbal, para a qual a margem medida na subseção 4.4.2 alcança 13,73.

6 Conclusão

Este trabalho descreveu dez métodos de avaliação de frases isoladas em português sob um formalismo único e os submeteu ao mesmo conjunto controlado de variantes, distribuídos por quatro dimensões: ortografia, gramática, estrutura e semântica.

A caracterização não produziu uma ordenação. Nenhum dos dez domina os demais, e as falhas observadas não se corrigem umas às outras porque nascem em níveis distintos: umas na definição do próprio método, outras na cobertura finita do recurso que ele consulta, outras ainda no insumo que um modelo anterior lhe entrega.

Sendo assim decorre que combinar os métodos não é conveniência de implementação, mas a resposta que o levantamento indica. Como as coberturas são complementares e as falhas não coincidem, o que um método deixa passar é frequentemente o que outro alcança — e a cadeia proposta reúne quatro etapas, uma por dimensão, decidindo pela existência de achados localizados em lugar de escore agregado. Cada item do laudo conserva a etapa que o produziu e as palavras envolvidas, e um único limiar figura em toda a cadeia.

Os limites são de duas ordens, e ambas recomendam cautela na leitura. O corpus é controlado e pequeno, derivado de uma única frase de referência, e cada método foi aplicado às variantes que exercitam a propriedade que ele mede, de modo que a complementaridade permanece argumento de construção mais do que medida. E os instrumentos são únicos — um analisador sintático, um corpus de contagens, um modelo mascarado —, nenhum treinado ou ajustado aqui, o que significa que parte do que se observou pertence a eles, e não às definições.

Desses limites decorrem os trabalhos futuros. O primeiro é completar a aplicação cruzada, submetendo cada método a todas as variantes, para que a complementaridade deixe de ser argumento e passe a ser medida. O segundo é ampliar o corpus, tanto em número de frases de referência quanto em tipos de desvio, e submetê-lo a julgamentos humanos de aceitabilidade, de que este trabalho não dispôs. O terceiro é variar os instrumentos, repetindo as medições sob outro analisador, outro corpus de contagens e outro modelo mascarado, o que permitiria separar o que pertence às definições do que pertence às ferramentas. O quarto é incorporar as regras escritas à mão à cadeia, uma vez que alcançam a escolha lexical, desvio que as quatro etapas atuais atravessam sem detectar. Resta, por fim, o erro factual, que é português correto e falso apenas em relação à base que originou o texto: sua verificação exige confrontar o enunciado com os campos que o geraram, e devolve o problema ao sistema gerador.

Referências

- DAMERAU, Fred J. A technique for computer detection and correction of spelling errors. **Communications of the ACM**, v. 7, n. 3, p. 171–176, 1964. DOI: 10.1145/363958.363994.
- FARUQUI, Manaal *et al.* Problems with evaluation of word embeddings using word similarity tasks. *In: PROCEEDINGS of the 1st Workshop on Evaluating Vector-Space Representations for NLP (RepEval)*. [S. l.: s. n.], 2016. p. 30–35.
- FUTRELL, Richard; MAHOWALD, Kyle; GIBSON, Edward. Large-scale evidence of dependency length minimization in 37 languages. **Proceedings of the National Academy of Sciences**, v. 112, n. 33, p. 10336–10341, 2015. DOI: 10.1073/pnas.1502134112.
- GIBSON, Edward. Linguistic complexity: locality of syntactic dependencies. **Cognition**, v. 68, n. 1, p. 1–76, 1998. DOI: 10.1016/S0010-0277(98)00034-1.
- KUKICH, Karen. Techniques for automatically correcting words in text. **ACM Computing Surveys**, v. 24, n. 4, p. 377–439, 1992. DOI: 10.1145/146370.146380.
- LAU, Jey Han; CLARK, Alexander; LAPPIN, Shalom. Grammaticality, acceptability, and probability: a probabilistic view of linguistic knowledge. **Cognitive Science**, v. 41, n. 5, p. 1202–1241, 2017. DOI: 10.1111/cogs.12414.
- LEVENSHTEIN, Vladimir I. Binary codes capable of correcting deletions, insertions and reversals. **Soviet Physics Doklady**, v. 10, n. 8, p. 707–710, 1966.
- LIU, Haitao. Dependency distance as a metric of language comprehension difficulty. **Journal of Cognitive Science**, v. 9, n. 2, p. 159–191, 2008.
- MIKOLOV, Tomas *et al.* Distributed representations of words and phrases and their compositionality. *In: ADVANCES in Neural Information Processing Systems (NIPS)*. [S. l.: s. n.], 2013. v. 26, p. 3111–3119.
- MŁKOWSKI, Marcin. Developing an open-source, rule-based proofreading tool. **Software: Practice and Experience**, v. 40, n. 7, p. 543–566, 2010. DOI: 10.1002/spe.971.
- NABER, Daniel. **A rule-based style and grammar checker**. 2003. Diplomarbeit – Universität Bielefeld.

- NIVRE, Joakim *et al.* Universal Dependencies v1: a multilingual treebank collection. *In: PROCEEDINGS of the 10th International Conference on Language Resources and Evaluation (LREC)*. [S. l.: s. n.], 2016. p. 1659–1666.
- PAULS, Adam; KLEIN, Dan. Large-scale syntactic language modeling with treelets. *In: PROCEEDINGS of the 50th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S. l.: s. n.], 2012. p. 959–968.
- RADEMAKER, Alexandre *et al.* Universal Dependencies for Portuguese. *In: PROCEEDINGS of the Fourth International Conference on Dependency Linguistics (Depling)*. [S. l.: s. n.], 2017. p. 197–206.
- SALAZAR, Julian *et al.* Masked language model scoring. *In: PROCEEDINGS of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S. l.: s. n.], 2020. p. 2699–2712. DOI: 10.18653/v1/2020.acl-main.240.
- SCHNABEL, Tobias *et al.* Evaluation methods for unsupervised word embeddings. *In: PROCEEDINGS of the 2015 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. [S. l.: s. n.], 2015. p. 298–307.
- SOUZA, Fábio; NOGUEIRA, Rodrigo; LOTUFO, Roberto. BERTimbau: pretrained BERT models for Brazilian Portuguese. *In: PROCEEDINGS of the 9th Brazilian Conference on Intelligent Systems (BRACIS)*. [S. l.: s. n.], 2020. p. 403–417. DOI: 10.1007/978-3-030-61377-8_28.
- WANG, Alex; CHO, Kyunghyun. BERT has a mouth, and it must speak: BERT as a Markov random field language model. *In: PROCEEDINGS of the Workshop on Methods for Optimizing and Evaluating Neural Language Generation (NeuralGen)*. [S. l.: s. n.], 2019. p. 30–36.