

Avaliação automática de frases em português: um estudo de técnicas

Matheus Sales

Resumo

Dada uma frase isolada, sem gabarito e sem referência, coloca-se a questão de quanto se pode afirmar a respeito de sua qualidade. Este relatório trata da avaliação automática de frases em cinco dimensões — ortografia, gramática, estrutura, semântica e coerência — em português brasileiro. O trabalho tem por objetivos comparar, nas dimensões que admitem concorrência, três a quatro técnicas rivais sobre um mesmo corpus rotulado de pares mínimos; discutir criticamente o emprego de um LLM como juiz; a partir dessas comparações, justificar as escolhas de uma *pipeline* de avaliação; e medi-la como um sistema de detecção (precisão, *recall*, F1, cobertura).

1 Problema

Métricas clássicas de classificação (acurácia, precisão, *recall*) pressupõem uma resposta correta única. Avaliar a boa formação de uma frase isolada rompe essa premissa: não há gabarito, não há referência, e a “qualidade” decompõe-se em perguntas independentes. Cabe considerar cinco dimensões, uma delas — a ortografia/mecânica — pré-requisito das demais:

Dimensão	Pergunta	Nível
Ortografia/mecânica	As palavras existem? Pontuação e maiúsculas?	frase
Gramática	Concordância, regência, tempos verbais?	frase
Estrutura	Tem predicado? É fragmento? É navegável?	frase
Semântica	A frase <i>significa</i> algo?	frase
Coesão/coerência	As partes se encadeiam?	texto

Tabela 1: As dimensões da avaliação. Cabe observar a última linha.

Coerência é relação, não propriedade. “O carro é azul” não é coerente nem incoerente — é apenas uma frase. Coerência é uma relação *entre* frases. Por isso o trabalho opera em dois níveis: o da frase (ortografia, gramática, estrutura, semântica) e o do texto (coesão e coerência).

O eixo: dimensão $\times$ juiz. Uma frase isolada não dispõe de termo de comparação; logo, o que organiza o problema não é “comparado com quê”, mas o cruzamento entre *o que se mede* e *quem mede*. Os juízes possíveis vão do léxico e do *parser* (baratos, exatos, localizados) ao modelo de linguagem e ao LLM (caros, aproximados, globais). A tensão central é: o *parser* indica exatamente o que está errado, mas é insensível ao significado; o modelo de linguagem percebe que algo está errado, mas não identifica o quê. Nenhum dos dois, isoladamente, constitui um avaliador.

Duas famílias de técnica. É preciso separar dois tipos de saída, sob pena de medir uma pela métrica da outra:

Tipo	Saída	Como se mede
Detector binário	dispara / não dispara	taxa de detecção + falsos positivos
Pontuador contínuo	um número	acurácia em pares mínimos

Tabela 2: Um pontuador com “6/6” ordenou o par corretamente; não encontrou nem localizou o erro.

Metodologia: pares mínimos. Comparar avaliadores exige um corpus com gabarito. A construção adequada é o *par mínimo*: uma frase-base correta e versões dela que alteram um único aspecto. Se duas frases diferem apenas na concordância e a técnica as ordena corretamente, então ela mede concordância — não comprimento, vocabulário ou assunto. Trata-se da metodologia do CoLA e do BLiMP.

Dois artefatos. Cabe distinguir um *estudo de técnicas* (que coloca concorrentes lado a lado e mede qual prevalece) de um *avaliador* ou *pipeline* (que escolhe uma técnica por dimensão e as integra num laudo). Este relatório realiza ambos e os articula: emprega o estudo para *justificar* as escolhas da *pipeline* e, em seguida, *medir* a *pipeline* montada.

2 Testes

2.1 Corpus

O corpus de frases é composto de 6 bases $\times$ 6 variantes = 36 frases. Cada base é uma frase correta; cada variante introduz um único defeito de um tipo conhecido (o gabarito), mantendo o restante idêntico. A isso somam-se *sondas* que não são pares mínimos, para expor falsos positivos: frases de palavras embaralhadas (desordem global), uma frase gramatical sem sentido e uma frase correta de vocabulário raro. Para a dimensão de coerência, usam-se parágrafos (coerentes, sem relação, coeso-mas-vazio e embaralhados).

Variante (base B1)	Frase
correta	Os pesquisadores analisaram os dados coletados durante o experimento.
ortografia	Os pesquisadores analizaram os dados coletados ...
conc. nominal	...os dados coletado ...
conc. verbal	Os pesquisadores analisou os dados ...
fragmento	Os pesquisadores que analisaram os dados ...
anomalia sem.	Os pesquisadores beberam os dados ...

Tabela 3: As seis variantes de uma base. O gabarito registra o defeito de cada uma.

2.2 Técnicas comparadas por dimensão

Dimensão	Técnicas concorrentes
Gramática	T1 <i>parser</i> (concordância na árvore) T2 LanguageTool T3 SLOR T4 PLL
Estrutura	E1 teste da raiz E2 complexidade E3 comprimento de dependência E4 legibilidade
Semântica	S1 surpresa S2 verbo mascarado S3 <i>embeddings</i> S4 LLM
Coerência	C1 sobreposição lexical C2 <i>entity grid</i> C3 <i>embeddings</i> C4 LM condicional

Tabela 4: Dezesesseis técnicas, quatro por dimensão.

Técnicas mapeadas, não implementadas. O estudo levantou, além das dezesseis medidas, soluções que exigem anotação ou recursos ausentes, deliberadamente deixadas de fora: o classificador supervisionado de aceitabilidade (estilo CoLA, avaliado por MCC), que demanda dados rotulados; a inferência de linguagem natural (NLI, com recursos do ASSIN/ASSIN 2) e a rotulagem de papéis semânticos (SRL/WSD), para a semântica; os índices de Yngve e Frazier, que requerem árvore de constituintes indisponível no `pt_core_news_sm`; e as cadeias lexicais sobre ontologia (WordNet), para a coerência. Registrá-las delimita o alcance do que foi de fato medido.

Protocolo. Cada técnica é medida por: (i) taxa de detecção por tipo de defeito e falsos positivos (detectores binários); (ii) acurácia em pares mínimos — a frase correta vence a corrompida? (pontuadores contínuos); (iii) custo em milissegundos por frase; e, para coerência, (iv) o teste de embaralhamento: a ordem original deve pontuar acima de suas permutações, contando-se os empates no topo.

Instrumentos de validação. Além da acurácia em pares mínimos e da taxa de detecção com falsos positivos, mobilizam-se instrumentos complementares conforme a família de técnica: o coeficiente de correlação de Matthews (MCC), para classificadores de aceitabilidade, cujas classes são desbalanceadas; Spearman e Kendall, para correlacionar a ordem produzida com o juízo humano; e o Kappa de Cohen ou o alpha de Krippendorff, para o acordo entre anotadores — que constitui o *teto* de qualquer métrica automática, pois nenhuma pode correlacionar bem com uma resposta humana que os próprios humanos não compartilham. Como referências externas, servem o CoLA e o BLiMP (inglês) e o ASSIN/ASSIN 2, o *Coh-Matrix-Port* (NILC/USP) e as tarefas do PROPOR (português).

Modelos e ferramentas. `spaCy` (`pt_core_news_sm`) para análise morfossintática; `pyspell-checker` (léxico de 417k palavras / 388M tokens) como dicionário e tabela de frequências; `LanguageTool` pt-BR (regras); `Qwen2.5-1.5B-Instruct` (modelo causal) e `BERTimbau` (modelo mascarado). Todos os testes foram realizados em CPU.

2.3 Fórmulas dos pontuadores por modelo de linguagem

A medida óbvia de aceitabilidade — a perplexidade — não serve, por confundir *raro* com *errado*: na execução, uma frase correta de vocabulário técnico recebe perplexidade ≈ 114 contra ≈ 61 de uma frase banal também correta, punição que é puro efeito de vocabulário. As correções abaixo normalizam essa distorção.

SLOR (*Syntactic Log-Odds Ratio*) desconta da probabilidade da frase aquilo que ela já teria pela frequência isolada das palavras, e normaliza pelo comprimento:

$$\text{SLOR}(s) = \frac{\ln P_{\text{LM}}(s) - \ln P_{\text{uni}}(s)}{|s|}. \quad (1)$$

PLL (*Pseudo-Log-Likelihood*) mascara cada *token* s_i e soma o log da probabilidade do original, avaliando cada posição com contexto dos dois lados:

$$\text{PLL}(s) = \sum_{i=1}^{|s|} \ln P_{\text{MLM}}(s_i \mid s_{\setminus i}). \quad (2)$$

Legibilidade (Flesch adaptado ao português, Martins et al. 1996):

$$\text{ILF} = 248,835 - 1,015 \frac{\text{palavras}}{\text{frases}} - 84,6 \frac{\text{sílabas}}{\text{palavras}}. \quad (3)$$

2.4 A *pipeline* sob teste

A *pipeline* de avaliação encadeia uma técnica por dimensão, na ordem do mais barato e exato ao mais caro e impreciso. Um mecanismo de *gating* condiciona as etapas estatísticas: a aceitabilidade (SLOR) e a etapa semântica só são avaliadas se não houver palavra fora do léxico — a mitigação da fraqueza conhecida do SLOR. A etapa semântica decide pela plausibilidade do verbo-raiz sob mascaramento, sinalizando o defeito quando a margem entre o melhor preenchimento esperado na posição e o verbo escrito ultrapassa um limite *relativo*, e não um valor absoluto de surpresa. Apresentam-se, abaixo, os dois detectores determinísticos que a sustentam:

```
def erros_concordancia(doc):          # T1: gramatica
    erros = []
    for t in doc:
        n, hn = t.morph.get("Number"), t.head.morph.get("Number")
        if t.dep_ in ("det","amod","acl") and t.head.pos_ in ("NOUN","PROPN"):
            if n and hn and n != hn:
                erros.append(f"nominal: {t.text} x {t.head.text}")
        if t.dep_ in ("nsubj","nsubj:pass") and t.head.pos_ in ("VERB","AUX"):
            if n and hn and n != hn:
                erros.append(f"verbal: {t.text} x {t.head.text}")
    return erros

def analisar_estrutura(doc):          # E1: estrutura (teste da raiz)
    raiz = [t for t in doc if t.dep_ == "ROOT"][0]
    predicado = raiz.pos_ in ("VERB","AUX") or any(f.dep_ == "cop" for f in raiz.children)
    return raiz, predicado
```

Para medir a *pipeline* como sistema, ela é executada sobre as 36 frases rotuladas — independentes das 8 frases sobre as quais foi construída (um teste de generalização) — e cada etapa é tratada como um detector binário: dispara diante do defeito de sua dimensão? Dispara indevidamente?

3 Resultados

3.1 Ortografia e mecânica

A camada de ortografia julga por léxico (lista de formas válidas) e por regras determinísticas de mecânica — inicial maiúscula, pontuação final, ausência de espaço antes de sinal e de palavra duplicada —, sugerindo a correção por distância de edição e frequência. É a única dimensão de veredito *exato*: ou a palavra consta do dicionário, ou não consta.

Onde acerta. O erro de grafia é apontado de imediato e com localização: “anlizaram” recai fora do léxico e a sugestão por frequência recupera “analisaram”. Nenhuma camada estatística posterior alcança essa precisão, ao custo de microssegundos.

Onde falha. Dois modos previstos. O erro de escolha — palavra existente empregada no lugar errado — escapa ao dicionário: “Ele estudou *mais* não passou” e “A dois anos que não o vejo” atravessam sem uma única forma desconhecida, por dependerem de contexto. Além disso, nome próprio, termo técnico e estrangeirismo são reportados como desconhecidos sem serem erros — a lista de exceções nunca se encerra. Daí a ortografia preceder as demais etapas: palavra fora do vocabulário desregula qualquer medida de frequência, como o SLOR evidencia adiante.

3.2 Gramática

Nenhum pontuador domina. O PLL vence dentro do par mínimo (30/30 contra 29/30), mas penaliza vocabulário raro; o SLOR o corrige. As sondas expõem a troca:

Defeito	Detectores (/6)		Pontuadores (pares /6)	
	T1 <i>parser</i>	T2 LangTool	T3 SLOR	T4 PLL
correta	0	0	—	—
ortografia	0	6	5	6
conc. nominal	5	4	6	6
conc. verbal	6	1	6	6
fragmento	0	0	6	6
anomalia	0	0	6	6
Total pares			29/30	30/30
Custo/frase	~4 ms	~0,4 s	~0,5 s	~0,4 s

Tabela 5: Gramática. O *parser* detecta concordância verbal 6/6 contra 1/6 do LanguageTool (ferramenta madura de 259 MB), a ~1% do custo; o inverso vale na ortografia. São complementares.

Sonda	SLOR	PLL
rara_correta (correta!)	+2,01	-2,45
vazia (sem sentido)	-0,90	-1,92
embaralhada_1 (agramatical)	-0,54	-6,85
embaralhada_2 (agramatical)	+1,43	-6,89

Tabela 6: O PLL atribui à frase correta de vocabulário raro nota inferior à da frase sem sentido; o SLOR falha no sentido oposto, favorecendo palavras embaralhadas. O PLL prevalece entre pares; o SLOR, entre frases de conteúdos diferentes.

3.3 Estrutura

Defeito	prof.	orações	ramif.	dep. len	cruz.	Flesch
correta	3,8	1,7	1,00	1,43	0	26,0
conc. verbal	4,0	1,7	1,00	1,39	0	31,1
fragmento	4,8	2,7	1,00	1,50	0	38,5
anomalia	3,8	1,7	1,00	1,43	0	32,7

Tabela 7: Estrutura (médias). O teste da raiz (E1) detecta fragmento 6/6 com zero falso positivo — o melhor detector do estudo. **ramif.** é constante (1,00 é identidade matemática numa árvore) e **cruz.** é 0 em todo o corpus.

A legibilidade está anticorrelacionada com a correção. O fragmento (de estrutura incompleta) recebe Flesch 38,5, superior ao da frase correta (26,0); **embaralhada_2** recebe 61,1; e **rara_correta**, uma frase correta de vocabulário técnico, recebe -109,8. Como pontuador de pares, o Flesch alcança apenas 2/30 — abaixo do acaso. Custos: E1 ~3,5 ms, E4 (legibilidade) ~0,01 ms — a mais barata e a menos informativa.

3.4 Semântica

Os *embeddings* (S3) discriminam mal: a anomalia situa-se a 0,928 da base correta, mas a negação (“cresceu” vs. “não cresceu”, sentidos opostos) situa-se a 0,966 — *mais* próxima. O LLM (S4) acerta 4/6 e custa ~1,6 s, e erra justamente nos verbos de leitura idiomática possível (“fervor de gente”).

Defeito	S1 pico (nats)	S2 $\log P(\text{verbo})$
correta	7,72	-5,44
ortografia	10,75	-9,54
conc. nominal	8,60	-4,92
conc. verbal	8,45	-8,69
fragmento	7,68	n/a
anomalia	13,20	-18,16

Tabela 8: Semântica (médias). S2 (verbo mascarado) acerta a anomalia 5/6 contra 4/6 de S1 (surpresa), custando ~ 38 ms contra $\sim 0,5$ s — mais exato e $14\times$ mais barato. S2 é “n/a” em fragmento: sem verbo na raiz, não há o que mascarar.

Parágrafo	C1 lex.	C2 grid	C3 emb.	C4 LM
coerente_A	0,00	0,00	0,671	-1,970
coerente_B	0,00	0,00	0,671	-2,132
sem_relacao	0,00	0,00	0,548	-2,975
coeso_vazio	1,00	0,33	0,780	-1,932

Tabela 9: Coerência. C1 e C2 atribuem 0,00 aos parágrafos bem escritos (que variam o vocabulário) e nota máxima ao **coeso_vazio**, que repete a mesma palavra — favorecem a repetição, não a coerência.

3.5 Coerência

O teste de embaralhamento expõe o problema. C1 e C2 aparecem em “1º/24”, mas com 24 empates no topo: toda permutação recebe a mesma nota, e o “primeiro lugar” torna-se degenerado. Já o LM condicional (C4), única técnica com algum sinal, coloca **coerente_A** em 1º/24 e **coerente_B** em **9º/24** — *o segundo parágrafo contradiz o primeiro*. Com os recursos disponíveis (sem resolução de correferência, sem *parser* de discurso), não há técnica confiável de coerência.

3.6 O juiz LLM

Diferentemente dos detectores especialistas, um LLM munido de rubrica é o único juiz capaz de responder sobre todas as dimensões de uma vez e em linguagem natural — o que o torna o único apto a *explicar* o problema a quem escreveu. Essa generalidade tem preço: a nota provém de outro modelo falível, com vieses documentados.

Viés	Sintoma	Mitigação
posição	preferir a primeira opção apresentada	julgar duas vezes, com a ordem trocada
verbosidade	preferir a resposta mais longa	rubrica que premie a concisão
autopreferência	preferir o próprio estilo	juiz de família distinta da do avaliado

Tabela 10: Vieses documentados do juiz por LLM e as respectivas mitigações.

Sobre as frases do corpus, o juiz (Qwen2.5-1.5B) revelou quatro falhas. (i) Não discriminou: erro de concordância, anomalia semântica e frase sem sentido receberam a mesma nota 4. (ii) Não justificou: embora a rubrica exigisse “Nota: N — problema”, a saída trouxe apenas a nota. (iii) Sensibilidade ao formato: pelo *template* de chat oficial, respondeu “sem problemas” às quatro frases, inclusive à agramatical e à anômala. (iv) Viés de posição: ao comparar duas frases, apontou “B” nas duas ordens — seguiu a posição, não o conteúdo. Como pontuador de anomalia (S4), acerta 4/6 e erra justamente em “ferveram” e “assaram”, de leitura idiomática possível.

Leitura. Onde existe detector determinístico para a dimensão, ele supera o LLM — mais barato, mais exato e mais explicativo. A qualidade do julgamento escala com o porte do juiz, e um modelo de 1,5B fica aquém do necessário para a gramática do português; ainda assim, os vieses de posição e de verbosidade e a sensibilidade ao *prompt* não desaparecem com modelos maiores. Julgar duas vezes, com a ordem trocada, é o mínimo.

3.7 Justificativa das escolhas da *pipeline*

Etapa	Técnica	Justificativa (do estudo)
ortografia	léxico	o <i>parser</i> é insensível à grafia (0/6); erro de grafia exige etapa lexical dedicada, exata e ~ 0 ms.
gramática	<i>parser</i>	6/6 vs 1/6 do LanguageTool em concordância verbal; localiza o <i>token</i> .
estrutura	teste da raiz	6/6, zero falso positivo — o melhor detector do estudo.
aceitab.	SLOR (<i>gated</i>)	SLOR acerta 29/30; falha só com palavra OOV. Bloquear se houver OOV é a mitigação exata.
semântica	verbo mascarado	5/6 vs. 4/6 da surpresa; localiza no verbo-raiz e decide por margem relativa, sem escala absoluta.
coerência	<i>ausente</i>	o estudo não identificou técnica confiável; omiti-la é a decisão transparente.

Tabela 11: As escolhas de técnica seguem o vencedor do estudo em cada dimensão. Duas decisões validadas por omissão: o Flesch entra no laudo como número descritivo, nunca como veredito (é anticorrelacionado); a coerência permanece fora do laudo de frase.

3.8 Métricas da *pipeline* montada

Executada sobre as 36 frases rotuladas, a *pipeline* produz a matriz de roteamento e as métricas por etapa abaixo.

Defeito real	ortografia	gramática	estrutura	semântica
correta	1	1	0	0
ortografia	6	1	0	0
conc. nominal	1	5	0	0
conc. verbal	1	6	0	0
fragmento	1	1	6	0
anomalia	1	1	0	5

Tabela 12: Matriz de roteamento (disparos por tipo, 6 frases cada). A massa fica na diagonal (defeito $\rightarrow$ sua etapa); fora dela, falsos positivos.

Falhas com causa nomeada. Nenhum erro permanece oculto. Os cinco falsos positivos de ortografia e o falso negativo de semântica têm origem comum: *câmeras*, palavra comum ausente do léxico (base B2) — ela dispara a etapa lexical em toda a base e, por acionar o *gate* de OOV, impede a avaliação semântica da variante anômala dessa base. Os quatro falsos positivos de gramática vêm de “*a paciente*” (base B4), substantivo de dois gêneros que o *parser* marca como masculino. O falso negativo de gramática vem de “os *trabalho*” (base B3), em que o morfologizador *absorve* o erro. Todos constituem modos de falha previstos das técnicas escolhidas; nenhum resulta de ajuste ao corpus.

Etapa	TP	FP	FN	precisão	recall	F1
ortografia	6	5	0	0,55	1,00	0,71
gramática	11	4	1	0,73	0,92	0,81
estrutura	6	0	0	1,00	1,00	1,00
semântica	5	0	1	1,00	0,83	0,91
F1 macro-médio						0,86
Cobertura (defeito pego pela etapa certa)					28/30 (93%)	
Falso alarme (dispara em frase correta)					2/6 (33%)	

Tabela 13: Métricas da *pipeline* como sistema de detecção. A precisão plena da estrutura e da semântica reflete técnicas localizadas e exatas; a ortografia perde precisão pelo léxico finito, e a gramática, pelos substantivos de dois gêneros.

O *gating* do SLOR funciona. Nas sondas, a *pipeline* bloqueia o cálculo de SLOR em *embaralhada_2* (OOV: câmeras) e *rara_correta* (OOV: geomagnéticas), evitando o escore inflado.

Dois defeitos sem endereço. Todos os detectores da *pipeline* procuram um defeito *localizado*, e a anomalia global não o é. No conjunto de desenvolvimento (8 frases), duas escapam das quatro etapas. A frase de palavras embaralhadas atravessa sem disparo: as palavras existem, a concordância por acaso não colide, o *parser* impõe uma árvore de raiz verbal e o verbo-raiz, tomado isoladamente, é plausível. A frase gramatical sem sentido (“Ideias verdes incolores dormem furiosamente”) também escapa: o verbo “dormem” cabe na posição, e a etapa semântica, que julga apenas o verbo, não vê problema — o sem-sentido está na combinação dos adjetivos. Quem flagra ambas é o SLOR (−0,54 e −0,90), medida *global* e não localizável — é o preço de uma etapa semântica focada no verbo, e a razão para perguntar, ao desenhar um avaliador, quais defeitos do domínio não têm endereço.

3.9 Critério de decisão da etapa semântica

Um pormenor decide o desempenho da etapa semântica: como converter a pontuação contínua em veredito. A surpresa por *token* e o verbo mascarado *ranqueiam* a anomalia de modo idêntico (6/6 os dois); a diferença está no critério de corte:

Critério	S1 surpresa	S2 verbo mascarado
como ranqueador (anomalia vs. correta)	6/6	6/6
como detector de limiar fixo (> 12)	4/6	—
custo por frase	~0,5 s	~ 38 ms

Tabela 14: S1 e S2 *ranqueiam* de modo idêntico (6/6); o problema é o limiar absoluto, que perde B4 (“cantou”, 9,1) e B5 (“ferveram”, 9,2). O estudo já advertia: a escala não é absoluta.

Por isso a etapa semântica decide pela margem do verbo mascarado, e não por um limiar absoluto de surpresa: mede-se a diferença entre o melhor preenchimento esperado na posição do verbo-raiz e o verbo efetivamente escrito. Nesse critério, a anomalia destaca-se ($\geq 13,2$ nats de margem) da frase correta ($\leq 6,8$) sem depender de escala absoluta — recuperando “cantou” e “ferveram”, que o limiar fixo perdia —, ao custo de ~38 ms por frase contra ~0,5 s da surpresa. Como qualquer corte, permanece calibrado em 36 frases sintéticas com apenas seis anomalias: os valores de F1 são indicativos, não estimativas de produção.

Etapa	Previsto (estudo)	Medido (36 frases)
estrutura	raiz 6/6, zero FP	F1 = 1,00
gramática	<i>parser</i> 6/6 vs LT 1/6	F1 = 0,81
ortografia	<i>parser</i> insensível à grafia	recall 1,00, precisão 0,55
aceitab.	SLOR infla com OOV	<i>gating</i> funciona
semântica	verbo mascarado, margem relativa	F1 = 0,91
coerência	nenhuma técnica confiável	ausente do laudo

Tabela 15: O estudo justifica a *pipeline*, e a *pipeline* confirma o estudo.

3.10 Síntese

Conclusões. (i) A *pipeline* é fundamentada: cada etapa emprega o vencedor do estudo na sua dimensão, incluindo as duas decisões “invisíveis” (manter o Flesch fora do veredito e excluir a coerência do laudo). (ii) Os pontos fracos são conhecidos, não ocultos — cada falso positivo ou negativo tem causa nomeável (léxico finito, substantivos de dois gêneros, absorção morfológica). (iii) A etapa semântica confirma o achado do estudo: o verbo mascarado com margem relativa (F1 0,91) supera a surpresa com limiar fixo — que, como detector, acerta apenas 4/6 das anomalias —, por decidir sem escala absoluta.

Duas lições transversais. Para além das conclusões acima, dois padrões atravessam as quatro dimensões. Primeiro, custo não compra qualidade: em três das quatro, a técnica mais barata iguala ou supera a mais cara — o *parser* (~4 ms) vence a ferramenta madura em concordância verbal, o teste da raiz é o melhor detector do estudo, e o verbo mascarado (~38 ms) supera o LLM (~1,6 s). Segundo, combinar camadas supera escalar uma só: a melhor técnica semântica (S2) é justamente a que recorre ao *parser* para decidir onde interrogar o modelo — estrutura linguística e estatística se complementam, em vez de competir.

Referências

- Warstadt, Singh & Bowman (2019). *CoLA: The Corpus of Linguistic Acceptability*.
- Warstadt et al. (2020). *BLiMP: Benchmark of Linguistic Minimal Pairs*.
- Lau, Clark & Lappin (2017). *Grammaticality, Acceptability, and Probability*.
- Pauls & Klein (2012). *Large-Scale Syntactic Language Modeling* (SLOR).
- Salazar et al. (2020). *Masked Language Model Scoring* (PLL).
- Nivre et al. (2020). *Universal Dependencies v2*.
- Naber (2003). *A Rule-Based Style and Grammar Checker* (LanguageTool).
- Futrell, Mahowald & Gibson (2015). *Dependency Length Minimization*.
- Martins et al. (1996); Scarton & Aluísio (2010). Legibilidade e *Coh-Metrix-Port*.
- Barzilay & Lapata (2008). *Modeling Local Coherence (entity grid)*.
- Real et al. (2020). *ASSIN 2*; Souza, Nogueira & Lotufo (2020). *BERTimbau*.